

《看懂 AI》手机超大字版 · 第 1  
册 / 全六册

# 看懂 App、 模型与训练

先看见手机界面背后的  
系统



作者：爱吃的小柒

哥伦比亚大学 AI 研究及硅谷 AI 创业者

超大字版 · 2026-08-12

# 目录

序言 不是您不聪明，是  
系统没有向您解释 . . . . . 4

第 1 章 您打开的是  
App，不是模型 . . . . . 19

第 2 章 模型是怎样“学  
会”回答的 . . . . . 71

专题 看穿 AI 信息差销售 126

本册词汇卡 . . . . . 155

本册资料来源与核验说明 197

# 本册学习目标

区分 App、模型、API、账号与会员；看懂终端、本地与云端入口、数据污染，以及多个“专家按钮”、信息差收费和虚假微调怎样形成。

阅读技术词时，请依次看准确解释、明确标注的生活比方、比方边界，以及“作为用户，这对您意味着什么”。英文只用于帮助识别产品页面中的常见写法，旁边保留中文名称或说明。

# 序言 不是您不聪明，是系统没有向您解释



一位有生活经验的成年学习者，正在比较AI的聊天、写作、作图、修照片和编程用途。

几年前，手机上出现一个新功能，我们通常能猜到它大

概怎样工作。视频软件播放视频，地图软件寻找道路，购物软件连接买家和商家。今天，一个手机页面却可以同时声称自己会聊天、写作、画画、修复老照片、制作视频、指导健康、教授语言，甚至充当“私人助理”。

它究竟是什么？

如果一个销售人员告诉您，这些功能来自许多“顶尖 AI 专家”，每个专家都经过独家训练，您可能很难当

场判断。页面上的按钮确实不一样，回答的口气也确实不一样。

**【这是一个比方】** 从使用感觉上说，健康按钮像一位顾问，写作按钮像一位编辑，外语按钮又像一位教师。

**【比方的边界】** 这些按钮后面不一定存在三个不同的模型，更不存在三个具有真实职业资格的人。它们可能只是同一模型收到三段不同的隐藏指令。

然而，它们完全可能只是同一个模型收到不同指令后的不同表现。

经营者不一定训练过任何模型。他可能只是向一家模型公司购买了调用服务，再设计几个按钮，在后台写下“请扮演健康顾问”“请扮演文案专家”之类的指令。加入漂亮的图标、会员收费和商品链接后，这套服务就可以被包装成“全能 AI 平台”

”。换一组图标和名字，它还可以再次出售。

这里真正昂贵的，往往不是一次回答所消耗的模型计算，而是使用者不知道界面后面发生了什么。

这种差距叫作**信息不对称**：交易的一方知道系统怎样搭建、成本大约多少、数据去了哪里；另一方只能看到经过精心设计的页面和销售语言。一个人在这样的交易中受损，不说明她缺乏智力。



它说明产品没有透明地解释自己，而销售者利用了这种不透明。

这本书要补上的，就是这部分知识。

# 这不是一本劝您远离 AI 的书

AI 很有用。它可以陪您练习英语口语，把一篇难懂的文章分段解释，帮助您准备就医时要问的问题，比较两份公开资料，或者把一封意思零散的信整理清楚。

但它也可能：

- 用非常流畅的语言编造一个不存在的事实；

- 引用一篇并不支持其结论的文章；
- 根据商家提供的知识库，反复推荐某种产品；
- 在不知道您的完整病史时，给出听起来确定的健康建议；
- 把您输入的个人资料发送到您不了解的服务器；
- 让一个成本很低的普通功能，看起来像昂贵的独家技术。

学习 AI，不是选择“相信”或“不相信”它。更成熟的方式是：知道它在什么条件下有用，在什么条件下必须核验，以及谁在控制它所看到的信息。

# 我们会使用真正的工程词汇

书中会出现一些英文缩写和技术词，例如 API、Token、RAG、微调、多模态和智能体。它们第一次出现时都会得到解释，后面则会正常使用。

保留这些词不是为了炫耀技术。恰恰相反，骗子最容易利用的地方，就是把简单工程包装成神秘能力。只要理

解几个基本结构，许多宣传便不再神秘。

本书解释技术词时会使用固定的四步：

- <sup>1</sup> 先说明它在工程上实际是什么；
- <sup>2</sup> 再明确写出 “【这是一个比方】”，用生活场景帮助建立直觉；
- <sup>3</sup> 接着写 “【比方的边界】”，说明技术并不真的等同于生活场景；

4 最后回答 “【作为用户，这对您意味着什么】”，把知识落到选择、费用、隐私和核验上。

英文术语只用于帮助读者识别产品页面和新闻中的常见写法，旁边一定保留中文名称或解释。附录 A 提供完整中英文词汇表，阅读正文时不需要一次记住全部单词。大字体和清晰图解，是为了让眼睛少一些负担，不是为了让头脑少思考。

# 读完以后，您应该拥有五种能力

第一，看到一个 AI 页面时，能把“界面”和“模型”分开。

第二，看到“独家训练”“最新满血版”“内部渠道”等说法时，知道应该索取什么证据。

第三，面对一个看起来很专业的回答时，能判断它是否



需要来源、第二意见或专业人士。

第四，在付款和输入个人资料之前，能看懂账号、订阅、隐私和数据风险。

第五，能亲手建立一个适合自己的学习助手，让 AI 帮助自己思考，而不是替自己决定。

这本书不会要求您记住哪个模型永远最好。模型会更新，价格会变化，公司也会调整产品。我们真正要建立的

是一套不会随着产品名称改变而失效的判断框架。

当您能看见系统的结构，您就重新拥有了选择权。

# 第 1 章 您打开的是 App，不是模型

八个按钮，可能只连接一套后台能力

假设您打开一个手机网页，看见八个入口：

对话 作图 音乐视频 老照片修复

写作 我的助理 健康生活 艺术字

这些按钮很容易使人产生一种印象：每个入口后面都有一套专门的 AI，甚至有八支不同的专家团队。

事实可能完全不同。

“对话” “写作” “我的助理” 和 “健康生活” 可能都在调用同一个文字模型。区别只是经营者在后台放入了不同的指令。“作图” 和 “艺术字” 可能调用同一个图片模型。“音乐视频” 则可

能把您的要求转交给另一个第三方服务。


您看到的是八个房间，墙后可能只有两三台机器。

**【这是一个比方】** “八个房间、两三台机器”只是帮助理解前台按钮与后台能力数量可能不同。

**【比方的边界】** 真实软件没有这样的房间。一个按钮可以连续调用多个服务器和模型，一个模型也可以同时服务许多 App。

一次点击背后的真实服务链

这是结构示意图，不是服务器或模型的实际外观



从用户点击App，到产品后台加入隐藏说明、选择模型、调用搜索或商品规则，再返回答案的分层示意图。

要理解这件事，我们先把六个经常混在一起的概念拆开。

# 模型、App、账号和 API 分别是什么

## 1. 模型：产生内容的计算系统

模型是经过大量数据训练的计算系统。文字模型根据已经出现的文字，计算接下来哪些文字片段更合适；图片模型根据文字描述和图像规律生成或修改画面。

模型是能力的来源，但普通用户通常不会直接接触它的内部程序。

## 2. App 或网页：您看见和点击的界面

App 决定按钮放在哪里、字体多大、是否保存聊天、怎样付款，以及把您的请求送给哪个模型。

一个做得漂亮的 App 不一定有自己的模型；一个能力很强的模型，也可能被放进一个很粗糙的网页。



### 3. 产品：界面、模型和服务规则的组合

产品不只是模型。它还包括联网搜索、文件上传、语音输入、使用次数、客服、隐私规则、会员价格和退款安排。

两款产品即使调用同一个模型，也可能因为这些配套服务不同而产生不同价值。

## 4. 账号：谁拥有使用权和记录

账号影响谁能登录、谁能找回密码、谁能在用户界面查看历史记录，以及会员属于谁。平台工作人员、组织管理员或第三方处理者是否还能访问某些资料，则要看服务架构、权限设置、服务条款和隐私政策。

如果销售人员替您注册账号，并掌握手机号、邮箱、密码或验证码，那么您买到的

可能不是一个真正由自己控制的服务。

## 5. API：软件之间传递请求的接口

API 是 Application Programming Interface

（应用程序接口）的缩写，是两套软件按照规定格式互相提出请求、返回结果的接口。

一个 App 把您的问题按照规定格式发给模型公司的服务器，服务器返回答案，

App 再把答案显示在屏幕上。普通用户看不见这个过程，但大量第三方 AI 产品就是这样搭建的。

**【这是一个比方】** API 像餐厅前台使用的正式点菜单：前台按规定格式把订单送进后厨，再把完成的结果送回来。

**【比方的边界】** API 不是真人前台，只接受预先规定的数据、权限和格式。它还可能计费、限速和记录请求。

**【作为用户，这对您意味着什么】** 第三方 App 能回答复杂问题，并不能证明开发者训练了自己的基础模型。它可能按使用量购买 API。收费可以包含界面、客服和 workflow 价值，但经营者应当如实说明底层服务。

## 6. 会员：经营者制定的收费方案

会员可能购买更高次数、更快速度、较强模型、图片生成额度、人工服务或其他功能。它不是模型本身，也不自动证明产品拥有“独家AI”。

## 把六个概念放进一个生活比方里

**【这是一个比方】** 可以暂时把 AI 产品想成一家餐厅：App 界面是顾客看见的门面和菜单；模型是完成主要加工的后厨能力；API 是传递订单的接口；账号记录顾客身份和历史；会员是经营者设计的收费套餐；搜索和知识库像临时查阅的食谱与资料。

**【比方的边界】** 软件不是餐厅。数据可以同时被复制到多个系统，后台也可以在用户不知情时切换模型。这个比方只帮助区分角色，不能用于判断真实数据去了哪里。



**【作为用户，这对您意味着什么】** 看见功能丰富的 App，不要立刻推断它训练了许多模型。付费前分别核对：谁经营 App、实际调用什么模型、账号归谁、数据保存在哪里、会员究竟增加了什么。这样才能判断数千元买到的是技术、人工服务，还是仅仅更漂亮的菜单。

# LLM 不需要先做成 网页或 App 才能使用

许多人第一次接触 AI，是从手机里的聊天框开始，于是自然地认为：大语言模型必须装进一个有按钮、有头像、有会员页的 App，才能回答问题。

工程上并非如此。


LLM 是 Large Language Model（大型语言模型）

的缩写。模型负责计算；网页、App 和聊天框只是让人提交文字、查看结果的界面。开发者还可以在 terminal（终端）里使用模型。

终端也叫 command-line interface, CLI（命令行界面）。它通常是一块以文字为主的窗口。用户输入一行命令，电脑执行，再把结果显示出来。Windows 中的“终端”或“命令提示符”、

# macOS 中的“终端”都属于这一类工具。

同一个模型，不止一种入口  
界面负责收发信息；模型负责计算。两者不要混为一谈。



终端不是另一种模型，只是另一种操作界面  
终端既可连接云端，也可运行本地模型；费用、隐私和权限仍要分别核对

同一个模型可以通过官方网页、第三方App、终端或API使用；这些入口又可以连接云端模型或本机模型。

**【这是一个比方】** 网页、App 和终端像三种不同的门：旋转门、自动门和普通门。门的样子不同，进入的可能是同一座建筑。

**【比方的边界】** 软件入口不是真实的门。不同入口可能附带不同权限、系统提示词、联网工具、收费方式和数据记录，所以结果也不一定完全相同。

**【作为用户，这对您意味着什么】** 一个人向您展示一个漂亮的“AI 专家 App”，不能仅凭界面证明他拥有模型。做一个界面通常比训练模型容易得多。您要继续问：界面后面是谁的模型？钱付给谁？数据交给谁？

# 终端里的 AI 大致有三种用法

**【动态事实说明】** 下面的 Qwen Code 与 Ollama 命令、认证和安装方式核验于 2026 年 8 月 12 日。软件会更新，实际操作前应重新查看 [Qwen Code 快速入门](#)、[Qwen Code 架构说明](#)和 [Ollama 命令行说明](#)。

## 第一种：终端工具连接云端模型

终端工具可以把问题发送给模型公司的服务器，再在文字窗口里显示答案。它和网页聊天可能使用同一类云端模型，只是没有网页按钮。

例如，千问团队提供的 Qwen Code 是终端式 AI 工具。官方文档说明，安装和认证后可以在项目目录输入：

```
qwen
```



进入会话后，用户仍然用自然语言提出要求，例如“先阅读这个文件，再用中文解释”。这并不是说终端“训练出”了一个新模型；终端工具仍要连接选定的模型服务，并可能按照 Token 或套餐计费。

## 第二种：程序通过 API 直接调用模型

程序员可以不制作任何网页，直接在终端运行一段程序，通过 API 向模型发送请求。模型公司返回文字后，程序可以把它打印在终端、写进文件，或者继续交给另一个程序处理。

这解释了为什么小团队也能很快做出许多 AI 产品：先购买或申请一个模型 API，再制作按钮和收费页面即可。

产品可以有真实的设计价值，但不等于开发者从头训练了模型。

### 第三种：在自己的电脑运行本地模型

某些可下载模型可以在个人电脑上运行。以 Ollama 等本地运行工具为例，安装模型后，可以在终端输入类似下面的命令开始对话：

```
ollama run 模型名称
```

这里的“模型名称”必须换成实际安装的模型。模型文件可能占用数 GB 到数十 GB，速度取决于电脑内存、显卡、模型大小和上下文长度。

“在终端运行”与“在本地运行”不是同一件事。终端工具可以连接云端，本地模型也可以另外配一个网页界面。判断数据是否离开电脑，要看模型究竟在哪里计算

，而不是看屏幕是否像黑色命令窗口。

## 终端不等于免费，也不自动更安全

- 连接云端 API，通常仍会产生 Token 费用；
- 下载开放模型，不等于电脑、电力、维护和技术支持没有成本；
- 终端智能体可能获得读取文件、修改文件和执行命令的能力；

- 如果用户把 API key（API 密钥）交给陌生人，对方可能冒用额度；
- 如果从陌生链接复制命令，命令可能安装恶意程序或上传文件。

**【这是一个比方】** 终端像工具间，里面不只有螺丝刀，也可能有电钻和切割机。能力越直接，越需要知道当前工具能碰什么。

**【比方的边界】** 终端不是实体工具间。真正的风险来自软件权限、命令内容、账号密钥和数据流向；看见黑色窗口本身既不能证明危险，也不能证明安全。

**【作为用户，这对您意味着什么】** 普通聊天不必为了显得“高级”而改用终端。但理解终端的存在，可以打破一种常见误导：漂亮 App 不是昂贵模型能力的证明。若请人安装终端 AI，应要求对方解释模型来源、云端还是本地、预计费用、可访问的文件范围、怎样停止和怎样卸载。



# 一次点击在后台经历了什么

当您点击“健康生活”并输入“最近睡不好，应该怎么办”，后台可能按以下顺序工作：

您输入问题



手机网页或 App 收到文字



加入隐藏指令：

“你是健康顾问；语气亲切；回答结尾推荐本店产品”



选择一个文字模型



可选：搜索网页或查询商家的商品资料库



模型生成回答



程序插入会员、课程或商品购买按钮



答案显示在您的手机上

这条链路里，模型只负责一部分。经营者可以控制隐藏指令、搜索来源、商品资料 and 最后出现的购买入口。

因此，我们不只问“这个模型聪不聪明”，还要问：

- 谁设计了这个产品？
- 它把问题送到哪里？
- 它给模型看了哪些资料？
- 它希望我最后做什么？

## 同一个模型怎样变成多个“专家”

在调用模型之前，App 可以加入一段用户看不到的文字。这叫作系统提示词，也就是产品经营者预先给模型的工作说明。

例如：

按钮 A：请作为耐心的英语教师，每次只纠正一个错误。

按钮 B：请作为广告文案编辑，把文字改得更有感染力。

按钮 C：请作为健康生活顾问，回答后介绍我们的睡眠课程。

三个按钮可以调用同一个模型，却表现得像三个不同角色。

这种设计本身不一定有问题。一个正规产品也会用不同提

示词帮助用户完成任务。问题在于经营者是否如实说明：

- 这些角色是否真的使用了不同模型；
- 所谓“医学专用训练”有没有证据；
- 推荐内容是否带有商业利益；
- 用户花的钱具体购买了什么。

# “套壳” 什么时候只是开发，什么时候变成误导

人们常把调用别家公司模型的产品称为“套壳”。这个词容易把不同情况混在一起。

## 可能具有真实价值的第三方产品

- 把多个工具组合成更简单的工作流程；
- 为视力或操作不便者设计更好的界面；

- 提供可靠的专业资料库，并注明来源；
- 提供人工教学、审核、客服或售后；
- 对数据保存、模型来源和收费作出清楚说明。

## 高度可疑的产品

- 声称拥有“独家模型”，却说不出模型名称和版本；
- 把官方免费功能宣传成只有付高价才能获得；

- 用“内部渠道”“永久账号”“不限量”催促付款；
- 不说明开发者、隐私政策、自动续费和退款方式；
- 销售人员控制账号或要求提供验证码；
- 用健康恐惧推动购买唯一指定的商品；
- 把厂商模型的能力全部说成自己的研发成果。



关键不在于产品是否调用外部模型，而在于它是否对价值、成本和风险作出诚实说明。

## 一款 App 也可能悄悄更换模型

App 可以设置一个模型路由（model routing）系统，根据任务、成本、速度或会员等级选择不同模型。

**【这是一个比方】** 模型路由系统像分诊台：简单任务送到普通窗口，复杂任务送到专门窗口。

**【比方的边界】** 软件没有真人分诊员，路由也不一定以质量为首要目标；经营者可能主要按照成本选择模型。

**【作为用户，这对您意味着什么】** 同一个 App 中的两次对话可能实际使用不同模型。付费前要问能否查看模型名称、什么情况下会切换，以及会员是否真的获得更强模型。

- 简短问答交给便宜、速度快的模型；
- 复杂问题交给较强、较贵的模型；
- 图片交给图片生成服务；
- 会员用户使用较新版本；

- 免费用户使用旧版本或较小模型。

所以，只看 App 名称，不能知道每次对话实际用了什么。如果产品写着“由顶级 AI 驱动”，却不显示模型、版本和使用条件，这个说法几乎无法核验。

# 付款前真正应该知道什么

一个透明的 AI 产品，至少应该让用户比较容易找到以下信息：

**要核对的项目：**经营者

**您需要知道什么：**公司或开发者的完整名称

**要核对的项目：**模型

**您需要知道什么：**调用哪家模型、哪个版本；是否

会自动切换

要核对的项目：联网

您需要知道什么：是否搜索互联网；引用从哪里来

要核对的项目：数据

您需要知道什么：对话、照片和文件保存多久，用于什么

要核对的项目：费用

您需要知道什么：月付还是年付；是否自动续费；

## 额度怎样计算

**要核对的项目：**账号

**您需要知道什么：**是否由您自己的手机号或正式平台账号控制

**要核对的项目：**商品

**您需要知道什么：**推荐是否含广告、佣金或经营者自己的产品

**要核对的项目：**退出

**您需要知道什么：怎样导出记录、取消会员、删除账号和申请退款**

缺少一项信息不一定说明诈骗，但缺少得越多，您承担的不确定性越大。

## 手机实验：给一个 AI App 做“身份检查”

选择一个您已经安装的 AI App。先不要付款，也不要输入隐私资料。



## 第一步：查看应用商店页面

记录：

- App 的完整名称；
- 开发者或提供者的完整名称；
- 是否有应用内购买；
- 最近一次更新时间；
- 隐私政策链接。

不要只看图标。相似名称和相似图标都可以仿制，开发者名称更重要。

## 第二步：进入 App 的“关于”或“设置”

寻找：

- 使用了什么模型；
- 服务协议和隐私政策；
- 账号注销入口；
- 订阅管理入口；
- 客服和公司信息。

## 第三步：问客服或直接问产品

可以复制下面的问题：

请明确说明：这项服务当前调用的模型名称和版本是什么？是否会在不通知用户的情况下切换模型？回答是否会检索商家自己的商品资料？我的对话保存在哪里、保存多久？

AI 自己的回答不能代替公司的正式说明。最后仍要查看服务协议、隐私政策或官方客服答复。

# 可保存的判断卡：我到底在用什么

在付款前，用一句话填完每个空格：

我使用的 App 是：\_\_\_\_\_

经营者是：\_\_\_\_\_

它调用的模型是：\_\_\_\_\_

模型版本是：\_\_\_\_\_

它是否联网：\_\_\_\_\_

它是否推荐自己的商品：\_\_\_\_\_

我的账号由谁控制：\_\_\_\_\_

费用和取消方式：\_\_\_\_\_

如果多数空格无法填写，不要因为“已经用了几天”或

“销售人员很热情”而增加投入。无法解释清楚的产品，不适合承载您的健康资料、照片、身份证明或大额付款。

## 本章小结

请记住三个判断：

- <sup>1</sup> 您点击的是 App，回答来自 App 组织的一整条服务链。
- <sup>2</sup> 多个用途按钮不等于多个模型，更不等于多次专业培训。

- 3 第三方产品不一定不好，  
但它必须说清模型、数据、  
价格和商业关系。

# 第 2 章 模型是怎样“学会”回答的

【回看前文】 [第 1 章](#)已经解释了模型、App、API、系统提示词和终端入口。本章只追问模型本身怎样训练，以及为什么训练完成后仍会说错；这些概念不再从头重复。

# 它不是在资料库里寻找一段现成答案

当 AI 在几秒钟内写出一封完整的信，人们很容易想象：它是不是从某个巨大的资料库里找出了一封相似的信，再复制给我？

这并不是大语言模型最主要的工作方式。

大语言模型在训练中阅读大量文字，从中学习语言和信息之间的统计关系。回答时



，它根据您的问题和已经生成的内容，一步一步计算接下来出现什么文字片段更合适。

这些小片段叫作 Token。


一个 Token 可能是一个汉字、一个词的一部分、一个标点或几个字符。模型生成一句话，实际上经历了许多次“下一片段应该是什么”的计算。

**【这是一个比方】** Token 有点像拼图块：一段文字先被拆成许多块，模型根据已经出现的块计算下一块。

**【比方的边界】** Token 不固定等于一个汉字或单词，不同模型拆分文字的方法也不同。模型生成文字的内部数学过程远比摆放普通拼图复杂。

**【作为用户，这对您意味着什么】** 很多模型接口按输入和输出 Token 收费。长文件、长对话和很长的回答都会增加用量；“一次聊天”不是一个固定成本单位。

“训练模型”和“使用模型”不是同一时刻



一次普通聊天通常不会自动重新训练整个基础模型；产品可能另行保存对话或记忆

模型训练与用户实际使用是两个阶段：训练用数据和反馈调整参数，用户使用由训练后的模型根据当前输入计算输出。

这听起来似乎只是自动补全，为什么最后却能写文章、解释概念和解决问题？因为当训练规模足够大时，要持续预测合理的后文，模型必须学会许多隐藏结构：语法、概念关系、常见事实、文章格式、推理模式以及人们完成任务的方式。

但这里有一个非常重要的区别：

模型首先被训练成生成合适的后文，不是被直接训

练成一台永远说真话的事实机器。

这既是它能力的来源，也是它会犯错的原因之一。

## 从训练到产品通常经历哪些阶段

不同公司使用的具体方法不完全相同。为了不把训练和产品上线混在一起，可以先看三个常见训练阶段，再看训练完成后的部署阶段。

## 第一阶段：预训练

模型阅读大规模文字、代码和其他形式的数据，反复练习预测缺失或接下来的内容。

在这个阶段，它逐渐学会：

- 语言怎样组织；
- 不同概念怎样共同出现；
- 问题和答案通常是什么关系；
- 文章、对话、表格和程序代码有哪些结构；

- 世界知识在公开资料中通常怎样被描述。

模型训练后形成大量参数（parameter）。参数是训练中调整出来的数字关系，共同影响模型怎样处理输入。

**【这是一个比方】** 参数可以暂时想成调音台上的许多旋钮：单个旋钮作用有限，许多旋钮一起决定最后的声音。预训练形成的能力，像大量规律被压缩进这些旋钮的组合。

**【比方的边界】** 参数不是可以逐个打开阅读的知识卡片，也不能简单说某个旋钮保存了某一个事实。模型更不是一排精确的百科全书条目。

**【作为用户，这对您意味着什么】** 厂商宣传参数数量时，可以把它看作模型规模信息之一，不能直接等同于正确率。数据质量、后训练、工具、速度和任务匹配同样重要。



## 第二阶段：指令训练

仅仅会继续写文字，还不等于会听懂“请比较”“请翻译”“请列出三种方案”这样的要求。

指令训练用大量任务示例，让模型学习怎样把人的要求转化为合适的回答形式。

**【这是一个比方】** 经过这一阶段，模型的使用感觉更像一个能够接受工作说明的助手，而不只是一个接着写文章的系统。

**【比方的边界】** 模型没有助手的职业责任和真实理解。它可能复述了要求，却仍然遗漏限制或生成错误事实。

## 第三阶段：偏好与安全训练

训练者会比较不同回答，告诉系统哪些更有帮助、更清楚、更安全。这些反馈可以来自人工，也可以由其他模型协助产生。

这一阶段会影响模型：

- 是否直接回答问题；

- 怎样承认不确定性；
- 遇到危险请求时怎样拒绝；
- 回答是简洁还是详细；
- 是否倾向于迎合提问者。

安全训练不是永久有效的真伪保证。它只能改变模型在某些情境下的行为倾向。

## 训练完成后的阶段：产品部署

部署（deployment）属于 AI 生命周期，但不是训练阶段。训练完成后，模型才会进入具体产品。产品经营者还能在模型之外加入：

- 系统提示词；
- 联网搜索；
- 专用知识库；
- 计算器、地图、日历等工具；

- 用户记忆；
- 商品规则和付费入口。

许多用户感受到的“AI 能力”，其实是模型与这些外部系统共同产生的。

**【作为用户，这对您意味着什么】** App 今天的回答方式发生变化，不一定是重新训练了整个模型。经营者可能只是更换系统提示词、搜索来源、知识库或安全规则。判断版本时，要分别问“模型变了没有”和“产品外层配置变了没有”。

# 数据污染：模型为什么可能把错误学进去

模型从数据中学习规律，因此训练资料的来源、质量和比例都会影响结果。这里用数据污染（data contamination / data pollution）作为一个便于普通读者理解的总称：本来希望模型学习的资料中，混入了错误、重复、过时、失去来源、比例失衡或不适合当前任务的内容。

这个总称下面还要区分几种不同问题。它们不能都叫“有人攻击了模型”。

## 第一种：资料本来就有错误或偏差

公开网页、论坛、广告、旧书、扫描文字和用户帖子都可能包含：

- 已经过时的政策、价格和医学说法；
- 互相复制的同一条错误信息；



- 广告伪装成经验或科普；
- OCR 识别错误、缺页和错误标签；
- 某些地区、年龄、语言或生活经验长期缺席；
- 只记录成功案例，没有记录失败与副作用。

模型不会自动知道每句话背后的作者、利益关系和证据质量。如果相似说法大量重复，它可能更容易学习到这种文字规律。

**【这是一个比方】** 可以把训练数据想成城市供水的上游。水源很多，但如果其中混入泥沙、旧管道锈迹或来源不明的排放，下游处理就必须识别和过滤。

**【比方的边界】** 数据不是水，错误信息也不会像泥沙一样自动沉底。训练团队可以清洗、去重、标注和评估数据，但无法用一个滤网保证所有事实永远正确。

## 第二种：有人故意进行数据投毒

数据投毒（data poisoning）是更具体的安全概念：攻击者故意把精心设计的错误或触发样本放进训练数据、微调数据或其他学习来源，希望降低模型整体质量，操纵某类答案，或者留下只在特定条件下出现的后门行为。美国国家标准与技术研究院的对抗性机器学习分类把 poisoning attack（投毒

攻击) 归为发生在训练阶段的攻击类型。中国《人工智能安全治理框架》也把数据投毒列为需要治理的风险。

普通网页里有一条错误，不一定是数据投毒。要称为“投毒”，通常需要存在操纵意图或攻击设计。无意错误、低质量资料和故意投毒的责任性质不同。

## 第三种：AI 生成内容重新进入下一轮训练

网上越来越多文字、图片和评价由 AI 生成。如果后来的训练数据不加区分地大量吸收前一代模型生成的内容，错误、陈词滥调和少数模式可能被反复复制，原始资料中较少见的表达和事实逐渐消失。

研究者把递归使用模型生成数据后出现的退化过程称为 model collapse（模型坍

塌)。2024 年发表于《自然》的研究在特定实验条件下发现，不加辨别地使用模型生成内容进行递归训练，会使原始数据分布中较少见的部分逐渐丢失。

这不表示“只要使用合成数据，模型一定会坏”。经过设计、筛选、验证，并与可靠的人类或真实世界数据结合的合成数据，也可以有训练价值。风险来自来源不清、比例失控和缺少质量控制，

而不是“AI 生成”四个字本身。

**【这是一个比方】** 递归训练有点像不断复印上一张复印件，而不再保存原稿。经过许多轮后，浅色细节可能越来越淡。

**【比方的边界】** 模型训练不是复印机。研究结果取决于数据比例、筛选方法、任务和训练设计；保留高质量原始数据、正确使用合成数据和进行评估，都可能改变结果。

## 第四种：模型没有被重新训练，但搜索或知识库被污染

第 1 章已经说明，产品可以在模型之外连接搜索、RAG 知识库和用户记忆。

如果这些外部资料被加入虚假文档、广告、过期制度或恶意指令，模型也可能在当前回答中引用错误内容。

这种 知识库污染 (knowledge-base poisoning) 或检索污染，不一定改变基础



模型参数。它更像在回答前把一份有问题的材料放到模型面前。安全研究已经展示，攻击者可以设计容易被检索到的段落，使 RAG 系统朝指定错误答案偏移。

因此要分清：

**污染发生在哪里：**基础训练数据

**会影响什么：**模型长期形成的广泛规律

用户应该追问什么：数据来源、清洗、评估和版本

污染发生在哪里：微调数据

会影响什么：特定格式、任务或倾向

用户应该追问什么：微调目标、样本来源和对照测试

污染发生在哪里：搜索或 RAG 知识库

**会影响什么：**当前回答引用的外部资料

**用户应该追问什么：**资料由谁加入、能否打开原文、多久更新

**污染发生在哪里：**当前对话和文件

**会影响什么：**这一次任务的上下文

**用户应该追问什么：**是否混入陌生指令、错误附件或隐私资料

## 数据清洗能降低风险， 但不能提供永久保证

模型开发者会使用过滤、去重、来源控制、人工标注、异常检测、红队测试和训练后评估等办法降低污染。

RAG 产品还可以限制谁能写入知识库、记录文件版本、审核来源，并在高风险回答中要求多来源核验。

这些措施都有价值，但“我们清洗过数据”仍然不是永远正确的证明。数据规模巨

大，事实会变化，攻击方法也会变化。

**【作为用户，这对您意味着什么】** 当 AI 给出一个流畅且多数网页都在重复的答案时，不要把“重复很多次”直接当成独立证据。重要结论要追到最早来源，检查日期、作者和利益关系。产品声称使用“专业知识库”时，要问谁能加入资料、是否保留版本、能否显示原文，以及怎样删除错误资料。

还要注意：您的一次普通对话不一定会立刻重新训练基础模型。是否用于训练、人工审查或产品改进，要看具体服务的隐私政策和账号设置，不能由“AI 会学习”四个字推断。

## 本节技术资料

- [中国《人工智能安全治理框架》2.0版发布说明](#)
- [NIST：对抗性机器学习攻击与缓解分类](#)

- 《自然》：递归使用模型生成数据时的模型坍塌研究
- PMLR：RAG 知识源投毒与检测研究

## 训练、微调、知识库和提示词不是一回事

商业宣传经常把所有定制都称为“训练”。技术上，这几种方法有明显区别。

## 提示词：给现有模型一份工作说明

例如：

你是一位耐心的英语教师。  
不要立即给答案，先指出  
一个线索。

模型本身没有改变。下一次换一段说明，它就可以扮演别的角色。成本低、速度快，也是大量“专属专家”的真正来源。



## 规则：程序直接决定什么时候显示什么

例如，只要用户提到“睡不好”，程序就在回答后显示睡眠课程链接。这甚至不需要模型作出商品判断。

## RAG：先查外部资料，再让模型回答

RAG 是 Retrieval-Augmented Generation 的缩写，中文常译为“检索增强生成”。它的基本过程是：

用户问题



从指定文件或网页中查找相关片段



把找到的片段和问题一起交给模型



模型根据这些片段组织回答

正规用途包括：让 AI 根据单位制度、产品说明书或课程材料回答，并给出出处。

但如果知识库里只有某家商店提供的宣传材料，回答也会受到这些材料的限制。

RAG 能让回答“依据资料

”，却不能自动保证资料本身公正、完整或真实。

## 微调：用示例继续训练 权重或适配参数

微调会用一批特定示例继续训练现有模型，使它更稳定地遵循某种格式、语气或任务模式。不同方法更新的范围不同：全量微调可能更新全部或大部分基础权重；LoRA 等参数高效方法可以冻结基础权重，增加并训练较小的适配参数。

微调可能有价值，但它不是魔法：

- 数据质量差，模型会学到错误；
- 示例带有销售偏见，模型可能更稳定地重复偏见；
- 微调不等于获得实时知识；
- 微调不自动产生专业资格；

- 经营者声称“微调过”，应说明数据范围、评估方法和适用边界。

## 为什么商家不必微调，也能让 AI 反复推荐商品

假设一个健康页面不断推荐某种中药或保健品，至少有五种可能：

- 1 隐藏提示词要求它优先介绍该商品；

- 2 搜索范围被限制在商家自己的页面；
- 3 RAG 知识库主要由产品宣传材料组成；
- 4 程序规则检测关键词后插入广告；
- 5 模型确实经过带有相关倾向的微调。

前四种通常比真正微调更容易、更便宜。因此，只根据回答风格，无法判断模型是否接受过专门训练。

您真正应该问的是：

- 推荐依据来自哪些资料？
- 是否存在商业关系或佣金？
- 有没有同样认真地说明不使用该商品的理由？
- 有没有列出风险、禁忌和证据不足之处？
- 能否提供独立于销售方的原始来源？

# 模型为什么会不准确

## 1. 它学到的是资料中的规律，也会继承资料的问题

训练资料可能包含错误、过时内容、互相矛盾的观点和社会偏见。规模巨大不等于每一部分都经过事实审查。



## 2. 它把知识压缩在参数关系中

模型不是逐条精确保存所有细节。常见模式可能记得较好，罕见姓名、日期、数字和出处更容易混淆。

### 3. 生成流畅回答比承认缺少证据更符合基础训练目标

如果一个问题看起来应该有答案，模型可能生成形式上最像答案的内容，即使缺乏可靠依据。这类看似合理却不真实的内容常被称为“幻觉”。

## 4. 问题可能含糊或带有错误前提

例如：“某位专家已经证明这种药有效，他用的是什么方法？”如果所谓证明并不存在，模型仍可能顺着提问的前提继续回答。

## 5. 模型可能过度迎合

当用户反复暗示自己想要某个结论时，部分模型会倾向于同意，而不是坚持指出证据不足。

## 6. 联网和工具也会出错

搜索可能找到低质量网页；网页可能已经过期；系统可能只读取摘要；引用可能和结论不匹配。使用了工具不等于工具结果被正确理解。

## “它听起来很确定” 不能作为证据

人类说话时，语气通常反映一定程度的信心。模型的语气则是生成风格的一部分。

它可以用犹豫的语气说出正确事实，也可以用非常确定的口气说出错误日期。粗体、编号、术语和完整引用格式都只能证明回答被组织得很好，不能证明内容已经核实。判断一条回答，应把“表达质量”和“证据质量”分开：

**表达质量：**是否清楚、易懂、有结构

**证据质量**：是否有原始来源和日期

**表达质量**：是否符合要求的语气

**证据质量**：来源是否真正支持结论

**表达质量**：是否给出具体步骤

**证据质量**：是否说明不确定性和反例

**表达质量：**是否看起来专业

**证据质量：**是否经得起独立来源核验

**手机实验：改变一个条件，看模型是否真的理解限制**

选择任意一个 AI，依次提出下面三个问题：

## 问题一

请介绍三种改善睡眠的日常方法。

## 问题二

请介绍三种改善睡眠的日常方法。不要推荐任何药物、保健品、课程或付费产品。



## 问题三

请把建议分成“有较强证据”“证据有限”和“只适合向医生询问”三类，并说明你无法知道我的哪些个人情况。

比较三个回答：

- 限制条件是否被遵守？
- 回答是否主动推销？
- 它是否承认不了解您的病史和用药？

- 它所谓“证据”有没有可核验来源？
- 如果重新提问一次，结论是否稳定？

这个实验不是为了让 AI 给您治疗方案，而是观察它怎样响应指令、边界和证据要求。

## 可保存的判断卡：它为什么这样回答

当一条 AI 回答影响您的购买或重要决定时，依次问：

这是模型原有的一般能力，还是产品加的指令？

它有没有搜索互联网？

它搜索的是整个网络，还是指定知识库？

回答里是否插入了固定商品规则？

所谓“专门训练”有什么可以核验的证据？

结论来自独立资料，还是销售方自己的资料？

如果回答错了，损失会有多大？

## 本章小结

- 1 大语言模型通过预测文字片段学习语言和知识结构

，不是逐条查询一部完美百科全书。

- 2 预训练、指令训练和偏好安全训练属于训练过程；产品部署是训练完成后的生命周期阶段。
- 3 提示词、程序规则、RAG和微调都能改变回答，但只有微调继续进行训练，并更新权重或新增可训练适配参数。
- 4 流畅、专业和确定的语气不能代替证据。

## 5 当回答推动购买时，要检查资料来源和经营者的利益关系。

下一章会集中讨论一个最容易误解的问题：既然模型知道那么多，为什么它仍会“像真的一样”编造事实，以及我们怎样根据错误代价决定核验强度。

# 专题 看穿 AI 信息差销售：先拆工程，再判断骗局

【回看前文】 [第 1 章](#)已经区分模型、App、API、账号、会员和终端；[第 2 章](#)已经区分训练、提示词、RAG 与微调。本专题不重复定义这些词，而是把它们用于一个现实问题：经营者究竟提供了什么，又可能隐瞒了什么？

# 为什么一个人很快就能做出八个“AI 专家”

如果经营者已经取得某个模型的 API 使用权，工程上可以这样做：

- 1 制作一个手机网页；
- 2 放上八个用途按钮；
- 3 为每个按钮准备不同的系统提示词；

- 4 把文字任务送给同一个 LLM，把图片任务送给一个图片模型；
- 5 在回答前加入商家资料，在回答后加入购买按钮；
- 6 设计会员、次数或积分收费。

这套产品可能是认真开发的，也可能只是粗糙包装。以上步骤通常不需要重新训练基础模型，更不能自动证明存在“医学专用模型”“国



学大师模型” 或 “内部独家模型” 。

**【作为用户，这对您意味着什么】** 第 1 章已经说明，界面和模型属于不同层。这里把这个概念用于付款判断：八个按钮可以有使用价值，但八个按钮本身不是八套昂贵模型的证据。

# 如果商家声称做过微调，应该追问什么

第 2 章已经解释，微调不是换一段角色说明，也不是只上传几份资料。它会通过训练更新模型权重，或者增加并训练适配参数；全量微调可能更新全部或大部分基础权重，LoRA 等参数高效微调则可以冻结基础权重、训练新增的较小参数。经营者声称做过 fine-tuning（

微调) 时，可以请他说明：

- 微调的是哪个基础模型和版本；
- 微调想改变格式、语气，还是专业任务表现；
- 用什么类型的资料训练，是否有合法来源；
- 用什么测试证明微调后更好；
- 哪些问题仍然不能回答；

- 用户输入是否还会被用于后续训练。

经营者不必公开全部商业秘密。但如果只能反复说“这是内部技术”“我们喂了海量资料”，却没有模型版本、测试方法和适用边界，那么“经过专门训练”仍然只是无法核验的宣传语。

# 现在常见的 AI 信息 差生意怎样让人多付 钱

以下模式根据 2025—2026 年监管通报、公安提醒和消费者调查整理。它们的严重程度不同：有些是正常服务但价格不透明，有些涉嫌虚假宣传，有些则会直接窃取账号、隐私或钱款。不要因为都被称作“套壳”就混为一谈。

# 1. 仿冒官方网页、图标和群组

页面看起来像官方，名称只差一个字母，客服头像也使用官方标志。用户因此输入账号密码、下载所谓更新包，或向“官方老师”付款。

2025 年，国家计算机病毒应急处理中心等机构发现仿冒 DeepSeek 的安卓木马：它以“需要更新”为由诱导安装子程序和开启无障碍权限，随后可能拦截短信、

窃取通讯录和应用列表。

2026 年市场监管部门公布的案例还包括使用与 DeepSeek 官方高度相似的页面、图标和“本地部署工具”字样，诱导用户误以为存在官方关系。

**识别重点：** 不从私聊链接安装；核对域名、应用商店中的开发者全名和官方公告；“界面很像”恰恰不是身份证明。

## 2. 把免费入口或公开资料包装成高价独家服务

商家可能收费教授如何打开官网、下载官方 App、复制普通提示词，或直接出售原本可以免费下载的软件。2025 年公安机关转载的调查中，有商家明确把这种做法称为赚取“信息差”；所谓本地部署教程的标价从极低引流价到高达数万元不等。教人使用 AI、提供上门安装和长期客服当然可以收费。



问题在于是否提前说清：软件本身是否免费，费用究竟购买教学、硬件、维护还是账号。

### 3. 一个模型改八套名字，分别卖八次

“写作大师” “健康顾问” “私人助理” 可能只是同一个模型加不同系统提示词。经营者再把每个入口描述成独立训练的专家，分别收取开通费。

**识别重点：** 要求列出每项功能的底层模型、版本和额外服务。不能回答，不代表一定诈骗；但意味着您无法判断自己为何要重复付费。

## 4. 用“自研”“微调”“私有知识库”制造技术权威

这三个词不是同一件事。接入别人的 API 不是自研基础模型；加入系统提示词不是微调；上传几份商家宣传材料做 RAG，也不等于材料经过独立医学或事实审核。

尤其要警惕健康入口：如果所谓“中医 AI”回答的结尾总是推荐同一家产品，真正起作用的可能是商品知识

库、隐藏指令或固定购买链接，而不是模型得出了独立诊断。

## 5. 低价试用、自动续费和积分耗尽

“一元体验” “前三天免费” “开通会员即可导出” 可能在小字中绑定自动续费；生成图片、视频或修复照片又可能额外消耗积分。用户以为购买了会员，后来才发现会员只提供进入资格，每次生成仍需购买点数。

**识别重点：** 付款前截屏价格页和续费条款；确认按周、按月还是按年；确认取消入口；区分会员费、Token费、图片积分和人工服务费。

## 6. “永久账号” “共享账号” 和旧模型冒充新模型

商家批量注册账号、共享一个账号，或用来历不明的接口提供旧版本模型，再承诺“永久不限量”。一旦上游封号、额度耗尽或经营者停止续费，用户的聊天记录和购买权益可能一起消失。

旧模型不一定完全没有价值：它可能便宜、速度快，处理简单改写也够用。问题是

经营者把旧版本冒充最新版本，或让用户为随时可能失效的使用权支付高价。

## 7. 先用免费课制造焦虑，再销售高价“变现系统”

常见话术包括“不会 AI 就会被淘汰”“十五天实现财富自由”“只有我们的软件才能全自动赚钱”。低价课或免费群只是入口，随后可能推销更贵课程、硬件、本地部署服务、素材包或加盟资格。

司法行政机关转载的 2025 年调查记录了“AI 视频制



作资源另收 4800 元”等情况；部分课程内容只是用模型生成普通文案，却用少数收益截图暗示可以稳定赚钱。

## 8. 用 AI 的亲切回答把人引向保健品、投资或其他高风险商品

AI 可以持续耐心聊天，这种体验容易被误认为没有利益关系的私人顾问。但产品后台完全可以要求回答先制造担忧，再推荐经营者自己的商品。

市场监管总局和中消协曾提醒，面向老年人的私域直播会利用“专家一对一”“免费健康咨询”“限时优惠”等方式销售价格虚高的药品或保健品。证券监管部门也提醒，有经营者以“AI 量化选股”“模型胜率高”为名收取高额服务费，而所谓软件可能只是公开软件加简单公式。

**识别重点：** 当建议同时推动付款时，把它视为销售意

见，而不是独立意见。健康、药物和投资结论必须离开销售页面，到无利益关系的正规渠道核验。

## 9. 用 AI 生成评价、案例和“老师形象”证明自己

头像、学员感谢信、成交截图、专家语音和成功案例都可能被生成或剪辑。几十条相似好评也可能来自同一批账号。

**识别重点：** 评价只能说明“有人发布了这段话”，不能单独证明身份、模型能力或收益。查公司主体、合同、官方域名、退款记录和可重复测试，比数好评数量更有用。

## 先判断性质，再决定是否付款

**情况：** 使用外部模型，清楚说明来源，并提供好界面、教学和客服

**可能的性质：**正常增值服务

**判断方法：**比较服务价值和总价

**情况：**软件本来免费，但商家明确收取上门安装和长期维护费

**可能的性质：**可以成立的服务

**判断方法：**把软件价格与人工服务价格分开

**情况：**隐瞒底层模型、夸大独家能力、续费规则藏得很深

**可能的性质：**高风险或不公平交易

**判断方法：**暂停付款，保存宣传和合同

**情况：**冒充官方、索要验证码、诱导安装陌生程序或转私人账户

**可能的性质：**可能涉及诈骗或恶意软件

**判断方法：**立即停止，联系平台、银行或警方

## 本专题小结

- <sup>1</sup> 按钮、角色和模型数量不是一回事。
- <sup>2</sup> API、系统提示词、RAG和微调会在不同位置改变结果。
- <sup>3</sup> 第三方服务是否有价值，要看真实增值、透明度和总价。

- 4 冒充官方、索要验证码和诱导安装陌生程序属于立即停止信号。
- 5 健康和投资建议一旦同时推动付款，就必须到无利益关系的渠道核验。

## 本专题动态资料来源

以下页面均于 2026 年 8 月 12 日核验。监管和产品情况会变化，出版前必须再次打开原文确认：



- 中央网信办：“清朗·整治AI应用乱象”专项行动
- 市场监管总局：人工智能领域不正当竞争典型案例
- 仿冒 DeepSeek 手机木马安全预警
- 公安机关关于免费软件、收费群组和高价教程的提醒
- 司法部智慧普法平台：AI培训套路调查

- 市场监管总局与中消协：老年人药品、保健品消费风险提示
- 深圳证监局：非法荐股骗局风险提示

# 本册词汇卡

这些词只选取本册实际使用的概念。每个词先给准确解释，再给明确标注的生活比方和比方边界。

# 人工智能 (Artificial Intelligence, AI)

准确解释：人工智能是一个很大的技术领域，研究和制造能够完成识别、预测、规划、生成内容等任务的计算系统。垃圾邮件过滤、地图路线、视频推荐和生成文章都可能使用 AI，但它们的工作方法并不相同。

**【这是一个比方】** “人工智能”像“交通工具”这个总称。自行车、火车、救护车和货轮都属于交通工具，却解决不同问题。

**【比方的边界】** AI不是一组真的车辆，也不存在一个统管所有AI的发动机。

“AI”只是大类名称，判断能力时必须继续问具体是什么模型和产品。

# 算法 (algorithm)

**准确解释：** 算法是一套解决问题或处理数据的明确步骤。排序联系人、推荐视频、寻找路线都可以使用算法。算法不一定会学习；许多算法由人直接写出规则。

**【这是一个比方】** 算法有点像菜谱：规定先做什么、后做什么，以及遇到某种情况怎样处理。

**【比方的边界】** 菜谱由厨师理解并灵活执行，计算机算法则需要能够被机器精确执行。现代机器学习模型的内部计算也远比普通菜谱复杂。

## 模型 (model)

**准确解释：** 模型是从数据中学习到一组数学关系、能够根据新输入产生预测或内容的计算系统。语言模型生成文字，图片模型生成或修改图像，分类模型判断内容属于哪一类。

**【这是一个比方】** 模型像一个经过大量练习形成工作习惯的助手：见过许多例子后，面对新材料会按学到的规律处理。

**【比方的边界】** 模型不是有生活经历、责任感和自我意识的人。所谓“学习”是调整大量数字参数，不是人类理解世界的完整过程。



# 机器学习 (machine learning)

准确解释：机器学习是让计算系统从数据和反馈中调整模型，而不是把每一种情况都写成固定规则的方法。

**【这是一个比方】** 固定规则像给人一本“看见红灯就停”的说明书；机器学习像给系统看许多道路例子，让它自己归纳哪些图像可能是红灯。

**【比方的边界】** 系统归纳的是数据中的数学规律，不会自动理解交通安全的社会意义。训练例子偏差，也会导致判断偏差。

## 生成式人工智能（ generative AI）

**准确解释：** 生成式 AI 是能够根据输入生成新文字、图片、声音、视频或代码的系统。它不是只在已有选项中选择，而是组合学到的规律产生新内容。

**【这是一个比方】** 它像一间可以按要求起草新稿件的工作室，而不只是一个从档案柜拿出旧文件的管理员。

**【比方的边界】** 生成内容并不表示系统拥有作者的人生经验或创作意图。新组合也可能复制偏见、混淆事实或接近训练材料中的已有作品。

## 训练 (training)

**准确解释：** 训练是用数据和反馈反复调整模型参数，使模型在某类任务上的输出逐渐符合训练目标的计算过程。训练大型模型需要大量计算资源，通常在用户开始聊天之前已经完成。

**【这是一个比方】** 训练像学生做大量练习题并根据批改调整答题习惯。

**【比方的边界】** 模型没有学生的主观体验，也不会因为一次聊天就自动把内容永久学会。训练中的“改正”是数学优化，不等于理解错误的社会后果。

## 推理或运行 (inference)

**准确解释：** 在 AI 工程中，推理是训练完成的模型接收一个新输入并计算输出的过程。用户每次提问、生成图片或识别声音，通常都在触发一次或多次推理。

**【这是一个比方】** 训练像厨师长期学艺，推理像厨师今天根据一张订单实际做一道菜。

**【比方的边界】** 模型推理不是人类在意识中权衡证据的同义词。有些产品把“推理模型”作为能力名称，也不表示其思维过程等同于人。

## 参数 (parameter)

**准确解释：** 参数是模型在训练中调整出来的大量数字。它们共同影响模型怎样把输入转换为输出。产品说“几十亿参数”是在描述模型规模的一种方式。

**【这是一个比方】** 可以把参数想成调音台上的大量旋钮：每个旋钮单独看意义有限，许多旋钮共同决定最后声音。

**【比方的边界】** 参数不是可以逐个读懂的知识卡片，也不能简单说某个参数专门保存某一事实。参数更多通常意味着容量更大，但不自动意味着每项任务更好。

## 数据集 (dataset)

**准确解释：** 数据集是为了训练、微调或评估而组织起来的一批数据，可以包括文字、图片、声音、标签和正确答案。



**【这是一个比方】** 数据集像一套教材、练习题和参考答案的集合。

**【比方的边界】** 数据集可能规模极大、来源复杂，也不一定经过像正式教材那样的编辑审查。错误、重复、偏见和未经授权内容都可能混入其中。

# 数据污染 (data contamination / data pollution)

**准确解释：** 本书用数据污染概括训练、微调或检索资料中混入错误、重复、过期、来源不明、比例失衡或不适合当前任务的内容。污染可能无意发生，也可能来自低质量收集；它不自动表示存在攻击者。

**【这是一个比方】** 它像资料仓库里混入旧版本、重复复印件和没有署名的便条，整理者若不核对，就可能把错误材料一起归档。

**【比方的边界】** 模型数据不是真实纸张，错误也不会自动露出颜色。过滤、去重和人工审核能降低风险，但不能保证每条事实永久正确。

# 数据投毒 (data poisoning)

**准确解释：** 数据投毒是攻击者故意把设计过的数据放进训练、微调或其他学习来源，以降低模型质量、操纵特定答案或植入触发行为。它是数据污染中的恶意安全问题，强调意图和攻击设计。

**【这是一个比方】** 它像有人故意把一批改过数字的假记录混入档案，希望以后查询者得到指定的错误结论。

**【比方的边界】** 真实投毒可能只改动少量复杂样本，也不一定能从单次回答直接证明。普通错误、观点分歧和资料过时不能自动定性为投毒。

## 模型坍塌 (model collapse)

准确解释：模型坍塌指生成模型在递归使用前代模型输出作为训练数据的某些条件下逐渐退化，丢失原始数据中较少见的模式或多样性。它是一类研究现象，不表示所有使用合成数据的训练都会失败。

**【这是一个比方】** 它像不断复印上一张复印件而不保留原稿，浅色细节可能一轮轮消失。

**【比方的边界】** 模型训练不是复印。高质量原始数据、经过验证的合成数据、合理比例和评估方法都可能改变结果，不能把这个比方写成必然结局。

## Token（文字片段）

**准确解释：**Token 是模型处理文字时使用的基本片段，可能是一个汉字、一个词的一部分、标点或几个字符。API 的文字使用量经常按输入和输出 Token 计费。

**【这是一个比方】** Token 有点像拼图块：一段话先被拆成许多块，模型再根据已有块预测下一块。



**【比方的边界】** Token 不总等于一个完整汉字或单词，不同模型的拆分方式也可能不同。模型不是先像人一样理解整句话，再机械拼图。

## 幻觉 (hallucination)

**准确解释：** 在生成式 AI 中，幻觉通常指模型生成了听起来合理、实际却错误、无依据或与来源不符的内容，例如编造书名、日期、引文或人物经历。

**【这是一个比方】** 它像一个人在记不清时，仍用符合故事结构的细节把空白补满。

**【比方的边界】** 模型并没有人类的视觉幻觉或故意撒谎体验。“幻觉”是行业比喻，真实机制是生成目标没有自动保证事实正确。

# 应用程序（application, App）

准确解释：App 是用户直接操作的软件产品，包括界面、账号、付款、权限、数据保存和后台服务。App 可以拥有自己的模型，也可以调用其他公司的模型。

**【这是一个比方】** App 像一家餐厅：用户看到菜单、座位和服务，后厨食材却可能来自许多供应商。

**【比方的边界】** 软件的数据流比餐厅复杂得多，同一个按钮可以同时联系多个服务器。界面漂亮也不能证明模型来源、安全或价格合理。

## 用户界面 (User Interface, UI)

准确解释：UI 是用户看见和操作的部分，例如按钮、菜单、输入框和结果页面。

**【这是一个比方】** UI 像汽车的方向盘、仪表盘和踏板，是驾驶者接触车辆的部分。

**【比方的边界】** UI 不等于后台能力。相同模型可以有完全不同界面，相似界面也可能连接完全不同的服务。

# 图形用户界面 (Graphical User Interface, GUI)

准确解释：GUI 是以窗口、图标、按钮、菜单和触摸操作为主的用户界面。手机 App 和网页聊天通常属于图形用户界面。GUI 可以让操作更直观，但它只是产品的一层。

**【这是一个比方】** GUI 像家用电器上的屏幕和按钮，让用户不用看内部线路也能操作。

**【比方的边界】** 软件界面不是真实电器面板；后台可以随时连接不同模型、规则和服务器。按钮数量不能证明模型数量。

## 终端 (terminal) 与命令行界面 (Command-Line Interface, CLI)

准确解释：终端是用户用文字命令与计算机程序交互的环境；CLI 是程序接受这些文字命令的操作方式。

LLM 可以通过终端工具连接云端模型，也可以在终端启动本地模型，不一定需要单独制作网页或 App。



**【这是一个比方】** GUI 像看菜单点菜，CLI 像把要求按文字直接交给工作台。两种方式可以把任务交给同一个后厨。

**【比方的边界】** 终端不是后厨，CLI 也不是模型。终端命令可能拥有读写文件或安装软件的权限；是否联网、怎样计费、数据去哪里，要看实际工具和模型配置。

# 应用程序接口 (Application Programming Interface, API)

准确解释：API 是两套软件按照规定格式互相请求和返回结果的接口。第三方 App 常通过 API 调用模型公司的服务。

**【这是一个比方】** API 像餐厅前台的点菜单：顾客按菜单格式下单，前台把请求交给后厨，再把结果送回。

**【比方的边界】** API 不是真人前台，不理解全部意图，只接受规定的数据、权限和格式。API 还可能计费、限速和记录请求。

## 服务器 (server)

**准确解释：** 服务器是向其他设备提供数据或计算服务的计算机系统。手机 App 常把问题发送到远程服务器，由服务器运行模型再返回结果。

**【这是一个比方】** 服务器像集中处理业务的后台办公室，许多前台窗口都把任务送到这里。

**【比方的边界】** 服务器不一定是一台实体机器，也可能是分布在多个数据中心的服务。数据经过哪里要以产品架构和条款为准。

## 模型路由 (model routing)

准确解释：模型路由是产品根据任务、价格、速度或会员等级，把不同请求交给不同模型的机制。

**【这是一个比方】** 它像医院分诊台：简单问题去普通窗口，复杂问题转给专门科室。

**【比方的边界】** 路由器不一定正确理解任务，也可能主要按成本而非质量选择模型。产品若不披露，用户可能不知道实际使用了哪个版本。

## 提示词 (prompt)

**准确解释：** 提示词是用户或程序交给模型的任务、问题、材料和限制。提示词可以是文字，也可以包含图片、声音或文件。

**【这是一个比方】** 它像交给合作者的一份工作说明。

**【比方的边界】** 模型不是会主动澄清一切的合作者。提示词再清楚，也不能给模型增加没有的资料、工具、权限或专业资格。

## 系统提示词 (system prompt)

**准确解释：** 系统提示词是产品在后台预先设置的高层工作说明，通常规定角色、格式、安全边界和工具使用。普通用户往往看不到完整内容。

**【这是一个比方】** 它像单位给员工的内部工作手册，客户只看到最终服务。

**【比方的边界】** 系统提示词不保证模型每次完全遵守，也可能被其他指令、工具结果或程序规则共同影响。



# 检索增强生成 (Retrieval-Augmented Generation, RAG)

准确解释：RAG 先从外部语料或数据源中检索相关片段，再把这些片段和问题交给生成模型回答。来源可以是内部文件、网页、数据库或动态索引，常用于最新资料 and 需要引用的问答。

**【这是一个比方】** 它像一场“开卷考试”：答题前先从约定的资料范围找相关页，再组织答案。

**【比方的边界】** 模型不是严格按考试纪律答题的学生。它可能找错资料、遗漏反例、误读片段或补入自身知识；资料架本身也可能片面。

## 微调 (fine-tuning)

**准确解释：** 微调是在已有模型基础上，用特定示例继续训练，使它更稳定地遵守某种格式、风格或任务行为。全量微调可能更新全部或大部分基础权重；LoRA 等方法可以冻结基础权重，增加并训练较小的适配参数。

**【这是一个比方】** 它像一位已有通识训练的员工，再接受一段岗位专项训练。

**【比方的边界】** 微调不等于获得专业执照，也不适合频繁更新每天变化的事实。专项训练材料有偏见，模型也可能更稳定地重复偏见。

# 本册资料来源 与核验说明

核验日期：2026 年 8 月 12 日。本册把标准机构、同行评审研究、政府或监管材料和产品官方文档分开使用。技术论文支持的是特定机制或实验边界，不代表所有模型都完全相同；产品命令、政策和网页以后可能变化。

# 模型训练、部署、微调与出错机制

- [NIST AI RMF : AI 参与者任务与生命周期](#)：区分模型开发与训练、产品部署、运行监测和贯穿生命周期的测试验证。
- [PMLR : Mechanics of Next Token Prediction with Self-Attention](#)：支持 Transformer 语言模型以输入序列为条件进行下一 Token 预测的机制说明。

- InstructGPT 原始论文：  
支持指令微调和人类反馈  
会改变模型回答行为；论  
文同时说明模型仍可能编  
造事实和犯错。
- NIST 生成式 AI 风险管理  
框架 NIST AI 600-1：支持  
“confabulation（虚构  
式错误）”属于生成式 AI  
的重要风险，流畅输出不  
等于事实可靠。
- LoRA 原始论文：说明全  
量微调可重新训练全部模

型参数，而 LoRA 冻结预训练权重、训练新增低秩参数。

## 终端、本地模型和动态产品事实

- [Qwen Code 中文快速入门与架构说明](#)：支持 `qwen` 启动、认证以及终端界面与模型服务分层的例子。



- [Ollama 命令行说明](#)：支持 `ollama run` 模型名称的本地模型入口示例。

## 数据污染、投毒、模型坍塌与 RAG 污染

- [NIST AI 100-2：对抗性机器学习攻击与缓解分类](#)：支持数据投毒是带有操纵意图、发生在学习过程中的攻击概念。
- [中国《人工智能安全治理框架》2.0 版发布说明](#)：

用于中国 AI 安全风险治理背景。

- 《自然》：递归训练中的模型坍塌研究与作者更正：支持特定实验条件下尾部信息可能丢失；不能外推为“所有合成数据都必然有害”。
- PMLR：RAG 知识源投毒与检测研究：支持外部知识源被恶意内容污染后，检索与回答可能被定向操纵。

# AI 信息差销售、仿冒与高风险收费案例

- 中央网信办：“清朗·整治 AI 应用乱象”专项行动  
：支持仿冒、套壳 AI 网站和应用等治理背景。
- 市场监管总局：人工智能领域不正当竞争典型案例  
：支持相似页面、图标和“本地部署工具”混淆案例。

- 仿冒 DeepSeek 手机木马  
安全预警：支持诱导更新、无障碍权限、短信、通讯录和应用列表风险。
- 公安机关关于免费软件、收费群组和高价教程的提醒：支持公开软件和资料被包装成高价服务的案例。
- 司法部智慧普法平台：AI 培训套路调查：支持变现承诺、课程收费和后续资源费案例。

- 市场监管总局与中消协：  
老年人药品、保健品消费  
风险提示：支持私域直播、  
健康咨询、限时优惠和高  
价商品的风险结构。
- 深圳证监局：非法荐股骗  
局风险提示：支持“AI 量  
化选股”等技术权威包装  
和高额服务费风险。

# 怎样理解这些来源

政府通报可以证明通报中的案例、机构、年份和行为，但不能证明所有类似产品都有同样问题。厂商文档可以证明其当时公开的命令和功能，不能独立证明“最好”或“最安全”。涉及付款、安装和账号时，仍要核对当前官方入口、开发者身份、合同、退款与隐私条款。