

《看懂 AI》手机超大字版 · 第 2
册 / 全六册

认识模型家族与定制方法

从 LLM、SLM 到 RAG、
微调与智能体



作者：爱吃的小柒

哥伦比亚大学 AI 研究及硅谷 AI 创业者

超大字版 · 2026-08-12

目录

第 3 章 AI 不是一种模型
，而是一整个工具家族 . . . 5

第 4 章 提示词、RAG、
微调、记忆、工具和智能
体 45

第 5 章 为什么有些模型
更适合某些任务 85

本册词汇卡 110

本册资料来源与核验说明 143

本册学习目标

理解不同模型和产品外层能力的分工；知道为什么没有永远的总冠军，并能为自己的真实任务设计比较测试。

阅读技术词时，请依次看准确解释、明确标注的生活比方、比方边界，以及“作为用户，这对您意味着什么”。英文只用于帮助识别产品页面中的常见写法，旁边保留中文名称或说明。

第 3 章 AI 不是一种模型，而是一整个工具家族



一套大型语言系统连接文字、图片、声音、视频、检索和本地小模型等不同工作台。

【前册回顾】 第一册第 1 章已经区分 App 与模型，第 2 章已经解释训练和参数。本章只用一张关系图快速回忆它们的位置，然后比较 LLM、SLM、多模态模型、图片模型、语音模型和嵌入模型，不再展开训练过程。

林老师第一次发现：
“AI” 这个词太宽了
林老师想整理父母留下的一箱老照片。她列出几个任务：

- 1 看清照片背面已经模糊的手写字；
- 2 修掉照片上的划痕；
- 3 给黑白照片上色；
- 4 根据她口述的经历写一篇家庭故事；
- 5 把故事翻译成英文，寄给在国外长大的晚辈；
- 6 最后做成一个只有家人能看的网页。

销售人员可能会说：“这些都可以用 AI。” 这句话没

有错，却不够准确。因为这六项工作并不一定由同一种模型完成。

识别手写字可能需要文字识别模型；修划痕和上色需要图片模型；整理故事和翻译需要语言模型；网页制作还会用到能够理解程序代码的模型。一个看起来“什么都会”的 App，常常只是在后台调度了多种工具。

【这是一个比方】 “AI”

可以暂时想成“交通工具”这个大类。火车、轮船、自行车和救护车都属于交通工具，但我们不会只问“哪个交通工具最好”，而会先问要去哪里、带多少东西、速度和安全有什么要求。

【比方的边界】 模型不是车辆，能力也不能只按速度和载重量衡量。这个比方只用于说明：AI 是大类，选择必须先看任务。

选择 AI 也是同样的道理。

人工智能、生成式 AI 和模型是什么关系

人工智能（Artificial Intelligence, AI）是一个很大的领域。只要计算系统执行了过去通常需要人类判断的任务，例如识别人脸、规划路线、判断垃圾邮件、推荐视频，都可能被归入人工智能。

生成式人工智能（Generative AI）是其中一类。它的特点是根据输入生成新内容，例如文字、图片、声音、音乐、视频或程序代码。

模型（model）是从数据中学到规律的计算机系统。模型接受输入，再产生预测、分类或新内容。

可以把三者的关系写成：

人工智能 AI

└—— 感知和识别：人脸识别、语音识别、OCR

└—— 判断和预测：垃圾邮件过滤、推荐系统

└—— 生成式 AI

└—— 语言模型：文字、翻译、代码

└—— 图片模型：生成和编辑图片

└—— 语音/音乐模型：合成语音和生成音乐

└—— 视频模型：生成或编辑连续画面

同一个产品可能把这些模型放在一个界面里，所以用户容易误以为它们是一个“万能大脑”。

大型语言模型（ Large Language Model, LLM）

LLM 是 Large Language Model 的缩写，中文通常叫大型语言模型。

这里的“大”，不只是说它读过的文章多，也指模型通常具有很多参数、需要大量计算资源训练，并能处理相当广泛的语言任务。参数可以先理解为模型在训练中调

整出来的大量数字关系。它们共同决定模型怎样理解上下文、选择后续文字并完成任务。

大型语言模型常见的用途包括：

- 对话和解释概念；
- 摘要、改写和翻译；
- 根据要求起草文章；
- 比较方案并整理表格；
- 阅读和解释程序代码；

- 在接入工具后搜索网页、计算或处理文件。

【这是一个比方】 大型语言模型的使用感觉像一位读过许多类型材料、可以快速起草多种文字的通才助手。

【比方的边界】 它没有真正的人生经验、职业资格和责任感；“读过很多”也不能保证精确记得每一条事实。

【作为用户，这对您意味着什么】 大型语言模型适合开放式解释、写作和比较，但高风险事实需要来源。不要因为它语言自然，就把它当成医生、律师或投资顾问。

大型不等于永远正确

一个模型参数更多、训练成本更高，通常有机会学习更复杂的规律，但不自动意味着它在所有问题上都更可靠。例如，一款很大的通用模型可能能解释许多医学术语，

却不知道某家医院今天的挂号安排；一款连接了该医院最新信息的小系统，反而能回答得更准确。前者拥有广泛能力，后者拥有当前任务需要的资料。

因此，要区分两件事：

- 模型本身的能力；
- 产品有没有把正确、最新的资料交给模型。

小型语言模型（ Small Language Model, SLM）

SLM 是 Small Language Model 的缩写，中文叫小型语言模型。有些资料也使用“轻量模型”“端侧模型”等说法，它们的范围并不完全相同。

小型语言模型通常参数更少，占用的存储和计算资源较少。有些可以在手机、平板

或个人电脑上运行，不必把每个请求都发送到远程服务器。

小模型可能更合适的情况

- 设备需要快速响应；
- 网络不稳定或不能联网；
- 数据不宜离开本机；
- 任务范围很窄，例如只做一种格式分类；
- 大量重复任务需要控制成本；

- 产品只需要简单改写、关键词提取或固定问答。

小模型的常见限制

- 对复杂、开放问题的推理能力可能较弱；
- 处理很长资料时更容易遗漏关系；
- 知识范围可能没有大型通用模型广；
- 对含糊指令和罕见任务的适应能力较弱。

但“小”不等于“差”。如果任务明确、训练或资料匹配，一款小模型可能比一款昂贵的大模型更快、更稳定。只有在它确实在本机处理、没有上传原始资料，并且遥测和服务政策也合适时，才可能更便于实现隐私保护。

【这是一个比方】 大模型像设备齐全的综合工作室，小模型像随身工具箱。修一颗松动的螺丝，随身工具箱可能更快。

【比方的边界】 模型没有真实工具箱，“本地小模型”也不自动保护隐私；App 仍可能上传数据或统计信息。

【作为用户，这对您意味着什么】 简单分类、短改写和本机任务未必需要最贵模型。遇到“必须购买最大模型”的销售话术，应先用自己的任务测试免费或较小版本是否已经足够。

例如，一个只在本机读取照片文件名或背面 OCR 日期、再按年份分类的小模型或程

序，未必需要具备写长篇论文的能力。如果要根据画面内容判断年代，则需要视觉模型，不能只因为模型较小就称它为 SLM。

多模态模型 (multi modal model)

“模态”可以理解为信息的形式：文字是一种，图片是一种，声音和视频也是不同形式。

能够处理两种或更多信息形式的模型，叫作**多模态模型** (multimodal model) 。

例如，您上传一张菜单照片，让 AI：

- 读出上面的文字；
- 翻译成中文；
- 解释一道菜可能含有哪些食材；
- 用语音念出外文菜名。

这个产品可能使用一个原生多模态模型，也可能在后台

组合图片识别、语言翻译和语音合成三个系统。对普通用户来说，两者在界面上很难区分。

因此，“支持图片”也可能有不同含义：

- 只会识别图片里有没有某种物体；
- 会读取印刷文字；
- 能理解图表和空间关系；
- 能根据文字修改图片；
- 能生成一张全新图片。

看到“多模态”三个字时，
仍要问它具体支持哪些输入
和输出。

【这是一个比方】 多模态
模型像一位能同时读信、看
照片、听录音的助手。

【比方的边界】 产品可能是
多个模型接力，不是一个模
型完成所有感官任务；支持
图片也不等于能正确阅读医
学影像。

【作为用户，这对您意味着什么】 购买前要实际测试需要的输入和输出。例如“能上传照片”可能只表示识别物体，并不表示能局部修复、保持人物身份或准确读取手写字。

图片生成和图片理解不是同一种能力

能够“看懂图片”的模型，不一定能够“画出图片”；能够画出漂亮风景的模型，也不一定能准确读取一张体检报告。

常见图片任务至少包括：

- 图像分类：判断图片大概属于什么类别；
- 物体识别：找到图片中的人物、车辆或其他物体；

- 光学字符识别（Optical Character Recognition, OCR）：把图片中的文字转成可编辑文字；
- 图片理解：回答关于画面内容和关系的问题；
- 图片生成：根据文字要求创造新画面；
- 图片编辑：修改已有图片的一部分；
- 照片修复：去除损伤、降低噪点、补全部分细节。

林老师上传老照片时，如果她只是想知道背面的手写字是什么，应优先使用文字识别和图片理解；如果她要修划痕，则需要图片编辑能力。把两者混在一起，模型可能在“看不清”的地方自行想象内容。

语音模型、音乐模型 和视频模型

语音识别 (speech recognition)

把人说的话转成文字，也叫自动语音识别。它适合口述文章、记录访谈和练习外语。

识别效果会受到口音、环境噪声、语速、多人同时说话和专业词汇影响。生成了一份整齐的文字记录，不代表每个专有名词都正确。

语音合成 (text-to-speech, TTS)

把文字转成声音，可以用于朗读、语言学习和辅助阅读。有些系统还能模仿某种声音。克隆真人声音涉及身份和诈骗风险。未经本人明确同意，不应上传他人的长段语音去制作“同款声音”。

音乐和视频生成

音乐模型可以根据风格、节奏、乐器和情绪要求生成片段；视频模型需要让连续画面在人物、动作、光线和空间上保持一致，计算量通常更大，也更容易出现细节变化。

“会生成一张好看的图”和“能生成一分钟人物稳定的视频”是难度非常不同的任务，价格也通常不同。

嵌入模型：不负责写答案，却负责“按意思找东西”

还有一类模型通常不直接和用户聊天，却在后台很重要，叫作嵌入模型（embedding model）。

它会把一段文字转成一组数字，使意思相近的内容在数字空间里更靠近。这样，用户即使没有输入完全相同的

词，系统也能按意思找到相关资料。

例如，林老师问：

父亲在信里提到“支边”，当时大概是什么生活背景？

家庭资料库里也许没有一句完全相同的话，但嵌入模型可以找出包含“到边远地区工作”“五十年代调动”“单位安排”等相关内容的信件片段，再交给语言模型整理。

这正是许多 RAG 系统的检索基础。下一章会详细解释。

【这是一个比方】 嵌入模型像图书管理员按“意思相近”摆放材料，不要求书名逐字相同。

【比方的边界】 数学上的相近不是对含义的完整人类理解，相近资料也可能互相抄袭或一起出错。

【作为用户，这对您意味着什么】 语义检索可以帮您在许多文件中找资料，但找到的片段仍需打开原文。搜索结果排在前面，只表示系统认为相关，不表示真实或权威。

一个 App 里的多模型协作

【这是一个比方】 可以把多模型协作想成接力：前一个系统处理完自己的部分，再把结果交给下一个系统。

【比方的边界】 软件之间传递的是数据，不是真人在跑步；任务还可能并行执行、反复返回或由一个多模态模型独立完成。

林老师完成家庭照片项目时，后台可能发生这样的协作：

扫描老照片



OCR 模型读取照片背面的字



图片模型去划痕并生成保守修复版



语音识别把林老师的口述变成文字



大型语言模型整理故事、核对时间线



翻译模型或多语言 LLM 生成英文版



代码模型帮助制作家庭网页

在用户眼里，这可能只是点了一个“家庭记忆助手”。在工程上，它可能是许多模型和工具的合作。

手机实验：先判断任务，再找模型

把下面任务抄到纸上，在每一项旁边写出它主要需要什么能力：

- 1 把一段英语录音转成中文文字；
- 2 检查一篇文章的逻辑是否连贯；
- 3 给旧照片去除一条折痕；
- 4 在五十份家庭信件中找出提到上海的内容；

- 5 根据一句描述生成一幅水彩风景；
- 6 在断网情况下把短信分成“重要”和“普通”。

参考思路：

- 第 1 项需要语音识别、翻译或多模态能力；
- 第 2 项主要需要语言模型；
- 第 3 项需要图片编辑或修复模型；

- 第 4 项适合嵌入检索加语言模型；
- 第 5 项需要图片生成模型；
- 第 6 项可能适合在本机运行的小型模型。

重要的不是背出唯一答案，而是开始用“任务—能力”的方式思考，而不是笼统地问“哪个 AI 最好”。

本章小结

- 1 AI 是一个大领域，生成式 AI 只是其中一部分。
- 2 大型语言模型（LLM）擅长广泛的文字、推理和代码任务，但大不等于永远正确。
- 3 小型语言模型（SLM）可能更快、更便宜、更适合本机和窄任务。
- 4 图片、语音、视频、嵌入和多模态模型承担不同工作。

- 5 一个“万能 App”可能由多个模型和工具协作，也可能由一个原生多模态模型完成多项任务；界面按钮本身不能说明后台结构。

第 4 章 提示词、 RAG、微调、 记忆、工具和 智能体

【回看前文】 第一册第 2 章简要区分过提示词、RAG 和微调；本册[第 3 章](#)介绍了模型家族。下面不重复定义，而是解释产品怎样组合这些部件。

同一个基础模型，为什么能变成不同产品


林老师发现两款 App 都声称使用同一家公司的模型。她问了同一个问题，回答却很不一样。

第一款 App 会列出来源，也会说“现有资料不足以判断”；第二款 App 无论问什么睡眠问题，最后都推荐一款价格很高的产品。

这不一定说明它们使用了不同模型。基础模型之外，产品还可以加入提示词、资料库、程序规则、记忆和工具。这些部分共同决定用户最后看到什么。

这一章把六个经常被混用的概念拆开。

RAG 与微调：都能改变结果，但改变的位置不同



两者可以同时使用；“有专用资料”不等于“训练了专用模型”

检索增强生成在回答前查询外部资料但不改变基础参数；微调则用示例继续训练权重或新增适配参数。

系统提示词（system prompt）：产品给模型的长期工作说明

普通用户在聊天框里输入的文字叫作用户提示词。产品经营者还可以在后台放入一段用户通常看不见的说明，叫作系统提示词（system prompt）。

例如：

你是本平台的健康生活助手。
回答要亲切、简短，不做明确诊断。
只使用我们提供的资料库。
当用户提到睡眠时，在结尾介绍睡眠课程。

只要改变这段说明，同一个模型就可以表现成教师、编辑、客服或销售顾问。

【这是一个比方】 系统提示词像单位给员工的内部工作手册，客户通常只看到服务结果。

【比方的边界】 模型不是真实员工，也可能没有完全遵守说明。系统提示词还会与用户输入、工具结果和程序规则共同影响回答。

系统提示词能影响行为，却不会给模型增加真正的专业资格。

【这是一个比方】 “请扮演医生” 不能把通用模型变成持证医生，如同给一个人穿上白大褂不会改变其训练经历。

【比方的边界】 白大褂只用来说明外在角色与真实资质不同，并不是在评价任何实际穿着或职业。

【作为用户，这对您意味着什么】 一个按钮写着“医学专家”或“法律顾问”，首先只证明产品给它起了这个名字。您还需要核对模型、资料来源、专业审核和责任主体。

检索增强生成（ RAG）：先找资料 ，再组织回答

RAG 是 Retrieval-Augmented Generation 的缩写，中文叫检索增强生成。

它解决的一个基本问题是：模型训练结束后，不会自动知道每一份新文件、内部制度或今天发布的通知。

更准确地说，RAG 会在回答时从外部语料或数据源检

索相关内容，再把检索结果交给生成模型。这个外部来源可以是家庭文件、公司知识库、数据库、开放网页或不断更新的索引，并不一定是封闭的“指定资料库”。

【前册回顾】 第一册第 2 章已经区分训练数据污染与知识库污染。RAG 资料被污染时，基础模型不一定发生变化，但当前回答仍可能被错误或恶意片段带偏。

RAG 的典型过程是：

用户提问



系统从外部语料或数据源检索相关片段



把问题和片段一起交给语言模型



模型根据这些片段组织回答



最好同时显示引用和原文位置

【这是一个比方】 RAG 像一场开卷考试：回答之前，先从一个约定的资料范围找出相关页，再组织答案。

【比方的边界】 模型不是严格遵守考试纪律的学生。它可能找错资料、漏掉反例、误读片段或补入自身知识；资料架本身也可能片面。

【作为用户，这对您意味着什么】 看见“接入专业知识库”时，不要只问有没有资料，要问资料由谁选择、多久更新、是否包含反对证据，以及引用能否点回原文。

一个可靠的例子

林老师把二十封经过家人同意的旧信保存在本机资料库。她问：“父亲第一次提到去西北工作是哪一年？”

系统先找出可能相关的信件，再让模型比较日期并回答。因为答案来自指定资料，林老师还能打开原信核对。

一个有偏向的例子

一家商店把自己的产品说明、顾客好评和销售话术放进资料库，却没有放入药品说明、独立研究、禁忌和负面证据。

模型严格依据这个资料库回答时，也会显得“有资料、有依据”，但它看到的资料本身已经被筛选。

所以，RAG 只回答了“模型参考了资料”，没有自动回答：

- 资料是否完整；
- 资料是否真实；
- 资料是否独立；
- 引用是否真正支持结论；
- 是否故意排除了相反证据。

微调 (fine-tuning)

: 用示例继续改变模型的习惯

微调 (fine-tuning) 是在已有模型基础上，用一批特定示例继续训练，使它更稳定地完成某类任务或遵循某种格式。

例如，一个机构需要把每封来信分成“咨询、投诉、建议、其他”，并严格输出固定表格。它可以准备许多正

确分类的示例，对模型进行微调。

微调适合改变：

- 固定输出格式；
- 特定文体和语气；
- 某类任务的稳定步骤；
- 对专业术语或标签的使用习惯。

微调通常不适合用来每天添加新闻，也不能自动保证医学正确。需要频繁更新的事

实，往往更适合通过 RAG 或搜索提供。

【这是一个比方】 微调像让一位已经接受通识训练的员工，再参加一段岗位专项训练，使固定工作做得更稳定。

【比方的边界】 模型不是有职业经验的员工；专项训练也不会产生执照、责任或实时知识。训练材料有偏见，模型还可能更稳定地重复偏见。

【作为用户，这对您意味着什么】 “我们微调过”不是充分的购买理由。经营者应说明微调改善了哪项可测试任务、使用什么类型数据、错误率如何，而不是只用“独家训练”抬高价格。

怎样判断“我们微调过”是否只是宣传

可以追问：

- 用了什么类型的数据？
- 数据是否获得合法授权？

- 微调想改善哪项具体任务？
- 用什么测试证明改善了？
- 错误率和不适用范围是什么？
- 当前实际使用的是微调版，还是遇到高负载就切换普通版？

如果经营者只能反复说“专属训练”“大师智慧”，却不能说明任务、数据和评估

，那么这句话的信息价值很低。

提示词、RAG 和微调的区别

方法：提示词

简单理解：给一份工作说明

是否继续训练：否

适合什么：快速改变角色、语气和格式

主要风险：指令可隐藏偏见或销售目标

方法：程序规则

简单理解：满足条件就执行固定动作

是否继续训练：否

适合什么：插入提示、商品或流程控制

主要风险：用户误以为是模型判断

方法：RAG

简单理解：先查外部资料再回答

是否继续训练：否

适合什么：新资料、私有文件、网页或数据库、可引用回答

主要风险：来源可能片面、过期或被污染

方法：微调

简单理解：用示例继续训练权重或适配参数

是否继续训练：是

适合什么： 稳定格式、风格和窄任务

主要风险： 数据偏见会被稳定放大

它们可以同时存在。一款产品可能先用系统提示词规定角色，再用 RAG 找资料，最后调用经过微调的模型。

工具调用 (tool use)

: 模型开始使用外部能力

语言模型本身主要生成和理解语言。为了完成现实任务，产品可以让它调用外部工具，例如：

- 搜索引擎；
- 计算器；
- 天气和地图服务；
- 日历和邮件；

- 数据库；
- 图片生成器；
- 程序代码执行环境。

例如，问“今天从上海到苏州最晚一班列车几点”，需要实时交通数据；靠模型训练时记住的知识无法可靠回答。

工具会增加能力，也会增加风险。模型可能选择错工具、把参数填错、误读结果，或

者在获得权限后执行不该执行的动作。

因此，涉及付款、发信、删除文件和公开发布时，应设置“执行前由人确认”。

【这是一个比方】 工具调用像一位助理不会亲自完成所有事情，但可以联系搜索、计算、邮件等不同部门。

【比方的边界】 模型可能联系错工具、填写错参数或误读结果。它没有真人助理对后果的完整判断。

【作为用户，这对您意味着什么】 只读文件和真正发送邮件、付款、删除内容的风险不同。给 AI 工具权限时应从最低权限开始，重要动作必须在执行前显示内容并由人确认。

记忆 (memory)

：产品保存了关于您的什么

有些产品会记住您的称呼、偏好、学习水平和过去任务。这种功能通常叫作记忆 (memory) 。

记忆可以让英语教师知道您正在学习旅行对话，也可能让产品长期保存您的疾病、家庭矛盾或消费偏好。

使用记忆前要知道：

- 哪些信息会被保存；
- 保存在哪里、多久；
- 能否查看、修改和删除；
- 是否用于推荐商品或训练系统；
- 退出账号后是否仍然保留。

“AI 好像越来越懂我” 既可能是便利，也可能说明它积累了越来越多个人资料。

【这是一个比方】 产品记忆像服务人员为熟客保留一张偏好卡。

【比方的边界】 这不是模型像人一样回忆往事。常见实现之一，是系统把偏好保存为原文、摘要、结构化档案或可检索记录，需要时再把相关内容放进上下文；也可能使用其他状态机制。保存范围和删除方式由产品设计决定。

【作为用户，这对您意味着什么】 打开记忆前，应查看、编辑和删除入口。学习偏好可以保存，疾病、证件、家庭矛盾和财务细节不应仅为“更懂我”而长期交给不透明产品。

智能体（agent）： 围绕目标连续计划和 行动

智能体（agent）不是一个完全统一的产品术语。通常它指一个能够围绕目标拆分步骤、调用工具、检查结果并继续行动的系统。

例如，林老师提出：

请把这十张照片按时间排序，读取背面文字，生成一个家庭事件表；遇到无

法判断的日期时列出来问我，不要自行猜测。

一个智能体可能：

- 1 读取照片；
- 2 调用 OCR；
- 3 比较日期和人物；
- 4 生成表格；
- 5 找到矛盾；
- 6 暂停并请求林老师确认；
- 7 根据确认结果更新表格。

这种连续工作比一次问答更方便，但必须限制权限。一个会规划的系统并不因此拥有作决定的责任。

【这是一个比方】 智能体像一位得到目标后会列计划、调用工具并汇报进度的项目助理。

【比方的边界】 它不具备人的责任、常识和授权判断。错误步骤可能被连续执行并放大。

【作为用户，这对您意味着什么】 智能体越能自动行动，越要关心停止按钮、权限、操作日志和人工审批。自动化程度高不是单纯优点，它同时扩大了出错影响。

一个商品推荐到底可能在哪里被加入

当 AI 推荐某种产品时，来源可能在不同层：

训练数据中本来就常出现该产品
或
系统提示词要求优先推荐

或

RAG 资料库只放了商家材料

或

程序检测关键词后插入广告

或

微调数据强化了某种销售话术

或

搜索结果受到广告和排名影响

只看最终回答，通常无法确定是哪一层造成。判断重点应从“AI 是不是故意骗我”转向更可核验的问题：谁设计了资料和规则，谁从推荐中获利，用户是否得到清楚披露。

手机实验：要求 AI 标出回答的来源层次

选择一个支持联网或文件上传的 AI，找一篇公开文章，先问：

不要搜索互联网，只根据你已有的知识，用三句话解释这篇文章讨论的问题。

再上传文章，问：

现在只根据我上传的文章回答。每个结论后写出对应段落，不要补充文章外

的事实。

最后允许联网，问：

现在寻找两个独立来源，
说明它们是支持、补充还是
反驳原文章。给出标题、
机构和日期。

比较三次回答，您会看到：
模型自身知识、指定资料
RAG 和实时搜索是三种不
同的信息条件。

本章小结

- 1 系统提示词规定长期工作方式，但不会创造专业资格。
- 2 RAG 让模型先找资料再回答，质量取决于资料库和引用。
- 3 微调会继续训练权重或新增适配参数，适合稳定行为，不等于实时知识或事实保证。
- 4 工具、记忆和智能体扩大了能力，也扩大了权限和隐私风险。

5 商品推荐可能来自许多工程层，关键是披露、证据和利益关系。

第 5 章 为什么有些模型更适合某些任务

【回看前文】 [第 3 章](#)已经介绍模型家族，[第 4 章](#)已经解释 RAG、微调、工具和记忆。本章把这些概念用于选择：不是再问“它们是什么”，而是判断哪种组合更适合您的任务。

“哪个模型最好” 少了后半句话

林老师问朋友：“哪个 AI 最好？”

一位朋友说某模型推理最强，另一位说另一款语音最好用，还有人说自己常用的产品免费，所以最划算。三个人可能都没有撒谎，他们只是评价了不同任务。

完整的问题应该是：

在什么任务、什么语言、什么资料、什么速度和费用限制下，哪个模型更合适？

【这是一个比方】 选择模型有点像选择相机：有的适合运动，有的适合人像，有的轻便适合旅行。只给一个总分，会隐藏许多真正影响使用体验的差异。

【比方的边界】 模型不是相机，模型的语言、工具、数据和安全差异也不能完全用镜头指标描述。这个比方只用于说明“适合哪项任务”比“总分第一”更重要。

【作为用户，这对您意味着什么】 不必为了追赶排行榜反复付费换工具。先列出自己最常做的三项任务，再用相同材料测试两款官方产品，通常比听销售者介绍更有判断价值。

差异一：训练数据的内容和质量

模型从什么资料中学习，会影响它熟悉哪些语言、文体、行业和文化背景。

如果一个模型见过大量高质量中文、古文、现代公文和中文互联网表达，它处理中文任务时可能更自然。如果代码数据和测试反馈充分，它可能更擅长编程。如果语音训练覆盖多种口音，它在真实环境中可能更稳健。

数据“多”不等于数据“好”。重复、错误、低质量翻译和营销内容也会进入训练。厂商通常不会公开完整训练资料，因此外部用户需要通过具体任务测试，而不能只听“训练了多少万亿数据”。

差异二：模型规模和结构

较大的模型通常有更多参数和计算能力，有机会处理更复杂的关系；较小模型则可能响应更快、费用更低，甚至能在本机运行。

模型结构也有差异。有些系统会让每次任务只使用部分专家模块，有些专门加强长文本、代码或视觉处理。普通用户不必掌握数学结构，

但要知道“参数更多”不是唯一指标。

如果任务只是把十条购物清单分组，一款小模型可能完全够用；如果要比较五份复杂合同中的冲突条款，可能需要更强模型、更长上下文和可靠检索。

差异三：后训练决定 “会不会按要求做事”

两个基础能力相近的模型，
经过不同的指令训练和偏好
训练后，表现可能很不一样
：

- 一个喜欢直接给结论；
- 一个会先澄清问题；
- 一个擅长严格输出表格；
- 一个写作生动，但容易添加没有提供的细节；

- 一个比较谨慎，遇到不确定问题更愿意停下来。

所以评估模型时，不只看“它知道多少”，还看“它是否遵守任务边界”。

差异四：上下文窗口和长资料处理

上下文窗口（context window）是一次任务中模型能够参考的输入和对话范围。窗口更长，意味着理论上可以放入更多资料。

【这是一个比方】 上下文窗口像一次会议桌能摊开的材料范围。桌子更大，可以放更多文件。

【比方的边界】 放得下不等于每一页都被正确理解。模型可能遗漏中间细节、混淆多个版本，也可能把不相关片段连在一起。

【作为用户，这对您意味着什么】 “能上传两百页”

不是完成长文档任务的证明。测试时要追问原文页码、例外条款和相互矛盾处，而不是只让模型写一个宽泛摘要。

但“能放进去”不等于“每一处都理解得一样好”。一份两百页文件即使成功上传，模型仍可能忽略中间的例外条款、混淆版本或在摘要时丢失细节。

长文档任务应测试：

- 能否找到明确位置；
- 能否给出页码或原文；
- 遇到矛盾时会不会指出；
- 问题换一种说法后是否仍能找到同一证据。

差异五：模型之外有没有好工具

实际产品的能力经常来自“模型 + 工具”：

- 搜索是否覆盖需要的网站；

- 是否能读取 PDF、表格和扫描图片；
- 引用是否能点回原文；
- 是否有代码执行、计算器或语音；
- 图片编辑能否只改指定区域；
- 视频能否保持人物和场景一致。

一款基础模型略弱、工具却非常适合任务的产品，可能比“排行榜第一”更好用。

差异六：速度、费用和隐私

更强模型通常需要更多计算，可能更慢或更贵。产品也可能在高峰期切换模型、限制次数或降低输出长度。

如果每次只是把语音转成购物清单，快速便宜比复杂推理重要；如果要判断一份高风险材料中的矛盾，多等几十秒可能值得。

本机小模型还可能让资料不离开设备，但必须确认产品确实在本地处理，而不是把数据上传后只宣传“端侧体验”。

按任务看“适合”， 不要按品牌贴永久标签

下面的表不是品牌排名，而是选择时要找的能力：

任务：日常聊天

重点能力：中文自然、语音方便、响应快

常见误区：把亲切语气当作事实可靠

任务：外语学习

重点能力：语音、纠错、可控制难度、对话记忆

常见误区：让 AI 一次纠正十个错误，造成挫败

任务：长文档

重点能力：长上下文、
RAG、精确引用

常见误区：只看能上传多少页

任务：写作

重点能力：遵守素材边界、
风格控制、修订能力

常见误区：一键生成后直接署自己的名

任务：图片生成

重点能力：构图、风格、文字和局部编辑

常见误区：只看第一张图是否漂亮

任务：老照片修复

重点能力：身份保持、局部修改、高保真

常见误区：把重新想象当作历史修复

任务：编程

重点能力：代码理解、工具调用、测试和调试

常见误区：复制代码直接运行，不看权限

任务：健康信息

重点能力：谨慎、来源、日期、不确定性

常见误区：把回答语气当作专业资格

自己做一个五题小测试

排行榜经常使用厂商或评测机构设计的题目。普通用户更应该设计自己的测试。

例如林老师为两个候选产品准备五项任务：

- 1 解释：用不省略因果的方式解释什么是 RAG，并举家庭信件的例子；

- 2 资料： 在一份上传文件中找出三个日期，给出原文位置；
- 3 写作： 只使用提供的事实写 300 字，不添加人物心理；
- 4 纠错： 进行五轮英语对话，每轮只纠正一个最重要错误；
- 5 诚实： 回答一个资料中没有答案的问题，看它是否承认找不到。

记录下面五个方面：

- 正确性；
- 是否遵守限制；
- 是否给出可核验证据；
- 使用是否方便；
- 免费额度或费用是否可接受。

同一个模型可能在第 1 题很好、第 2 题一般；另一款可能相反。这样得到的是适合自己的分工，而不是抽象的“冠军”。

本章小结

- 1 模型差异来自数据、结构、规模、后训练、上下文和工具。
- 2 产品体验还受到速度、费用、隐私和界面影响。
- 3 大模型适合复杂开放任务，小模型可能更适合快速、本机和窄任务。
- 4 不要给品牌贴永久标签；版本和产品会改变。

5 用自己的真实任务做小测试，比只看排行榜更可靠。

本册词汇卡

这些词只选取本册实际使用的概念。每个词先给准确解释，再给明确标注的生活比方和比方边界。

大型语言模型 (Large Language Model, LLM)

准确解释：LLM 是在大规模文字和其他数据上训练、能够执行广泛语言任务的模型。它可以对话、摘要、翻译、写作、解释代码，并在接入工具后完成搜索或计算。

【这是一个比方】 LLM 像一位读过很多类型材料、能够迅速起草多种文字的通才助手。

【比方的边界】 它不是受过真实职业训练、能承担责任的通才。读过的资料可能有错，生成的引用也可能不存在；“语言能力强”不等于“事实永远可靠”。

小型语言模型 (Small Language Model, SLM)

准确解释： SLM 通常参数更少、运行资源更低，有时可以直接在手机或电脑上运行。它可能适合快速、重复、范围明确的任务。

【这是一个比方】 大型模型像设备齐全的综合工作室，小型模型像随身工具箱：工具较少，但携带方便，特定小任务可能更快。

【比方的边界】 大小没有全球统一分界，工具箱也不一定比工作室更保护隐私；必须确认任务是否真的在本机完成、是否仍会联网。

上下文 (context)

准确解释： 上下文是模型在当前一次任务中能够参考的提示词、对话历史、文件片段和工具结果。它与训练时已经形成的参数知识不同。

【这是一个比方】 上下文像摆在助手当前书桌上的材料；模型参数则更像助手此前训练形成的工作习惯。

【比方的边界】 模型没有真正的书桌。上下文以 Token 形式进入计算，而且材料放进去不代表每个细节都会被同等重视。

上下文窗口 (context window)

准确解释： 上下文窗口是一次请求中模型能够处理的Token 总量范围，通常包括输入、对话记录、检索资料 and 输出。窗口越长，理论上能容纳的材料越多。

【这是一个比方】 它像一次会议桌能摊开的文件数量。桌子大，可以放更多材料。

【比方的边界】 桌上放得下
不等于与会者读懂了每一页。
长上下文模型也会遗漏中间
细节、混淆版本或错误建立
关系。

知识截止时间 (knowledge cutoff)

准确解释： 知识截止时间
通常指模型训练知识大致覆
盖到的时间边界。超过该时
间的新事件，除非产品联网
搜索或提供新资料，否则模
型可能不知道。

【这是一个比方】 它像一本在某日交稿的百科全书，交稿之后发生的事不会自动出现在已印出的内容里。

【比方的边界】 模型不是按日期整齐出版的百科；截止日前的罕见事实也可能不知道，截止日后的少量信息也可能通过后续训练、工具或产品更新进入。

多模态模型 (multimodal model)

准确解释：多模态模型可以处理文字、图片、声音或视频中的两种以上形式，有些还可以在不同形式之间转换。

【这是一个比方】 它像一位既能读信、看照片、听录音，又能把几种材料放在一起讨论的助手。

【比方的边界】 产品可能不是一个模型完成全部工作，而是多个模型接力。“支持图片”也不表示能准确理解所有医学影像、图表或手写字。

光学字符识别 (Optical Character Recognition, OCR)

准确解释：OCR 把图片中的印刷字或手写字识别成可以搜索、复制和编辑的文字。

【这是一个比方】 OCR 像抄写员看着照片，把看到的字重新打出来。

【比方的边界】 它不会自动理解全部语义，模糊字、竖排、特殊字体和手写体都可能抄错。得到可编辑文字后仍需对照原图。

语音识别 (speech recognition)

准确解释： 语音识别把录音或实时讲话转换成文字。口音、噪声、多人重叠和专业词都会影响准确性。

【这是一个比方】 它像会议记录员一边听一边打字。

【比方的边界】 系统没有记录员对人物关系和现场背景的完整理解。文字排得整齐，也可能把姓名、药名和数字听错。

语音合成 (Text-to-Speech, TTS)

准确解释： TTS 把文字转换成语音，可用于朗读、导航和语言学习。有些服务可以控制音色、语速和情绪，甚至模仿真人声音。

【这是一个比方】 它像一位按照文字稿朗读的播音员。

【比方的边界】 合成声音不是有情感经历的真人。模仿某个人的音色还可能造成冒充、诈骗和授权问题。

嵌入 (embedding) 与嵌入模型 (embedding model)

准确解释：嵌入模型把文字、图片等内容转换成一组数字，使意义或特征相近的内容在数学空间中更接近。它常用于语义检索、聚类 and 推荐。

【这是一个比方】 它像图书管理员不是按书名逐字相同，而是按主题把相近资料放到附近书架。

【比方的边界】 数学距离不是人类意义的完整理解，也会受训练数据影响。相近不等于事实一致，更不等于来源可靠。

知识库 (knowledge base)

准确解释： 知识库是为检索和回答组织的一组资料，可以是文件、网页、数据库记录或产品说明。它的范围由建设者决定。

【这是一个比方】 它像一个经过挑选的资料室。

【比方的边界】 被放进资料室的内容不自动真实、完整或中立。商家可以只放有利于自己的材料，也可能忘记更新旧版本。

检索增强生成 (Retrieval-Augmented Generation, RAG)

准确解释：RAG 先从外部语料或数据源中检索相关片段，再把这些片段和问题交给生成模型回答。来源可以是内部文件、网页、数据库或动态索引，常用于最新资料 and 需要引用的问答。

【这是一个比方】 它像一场“开卷考试”：答题前先从约定的资料范围找相关页，再组织答案。

【比方的边界】 模型不是严格按考试纪律答题的学生。它可能找错资料、遗漏反例、误读片段或补入自身知识；资料架本身也可能片面。

微调 (fine-tuning)

准确解释： 微调是在已有模型基础上，用特定示例继续训练，使它更稳定地遵守某种格式、风格或任务行为。全量微调可能更新全部或大部分基础权重；LoRA 等方法可以冻结基础权重，增加并训练较小的适配参数。

【这是一个比方】 它像一位已有通识训练的员工，再接受一段岗位专项训练。

【比方的边界】 微调不等于获得专业执照，也不适合频繁更新每天变化的事实。专项训练材料有偏见，模型也可能更稳定地重复偏见。

记忆 (memory)

准确解释： AI 产品中的记忆通常指系统保存用户偏好、背景、过去对话摘要或结构化记录，并在以后任务中检索或重新提供给模型；具体实现并不唯一。

【这是一个比方】 它像服务人员为熟客保存了一张偏好卡。

【比方的边界】 这不是人类有意识的回忆。保存什么、保存多久、能否删除由产品设计决定，也可能带来画像和隐私风险。

工具调用 (tool use / function calling)

准确解释：工具调用让模型按规定格式使用搜索、计算器、日历、数据库、邮件或程序执行器等外部功能。

【这是一个比方】 它像一位助理不会亲自完成所有专业操作，但可以拿起电话联系不同部门。

【比方的边界】 模型可能联系错工具、填写错参数或误读返回结果。涉及付款、发送和删除时仍需人工确认。

智能体 (agent)

准确解释： 在当前 AI 产品中，智能体通常指能够围绕目标拆分步骤、调用工具、检查结果并继续行动的系统。这个词在行业中没有完全统一的产品定义。

【这是一个比方】 它像得到一个目标后，会自己列计划、找资料、使用工具并汇报进度的项目助理。

【比方的边界】 智能体不具有人的责任、常识和授权判断。它能连续行动，恰恰意味着权限错误可能被连续放大，因此需要审批和停止机制。

基准测试 (benchmark)

准确解释： 基准测试是一组固定任务和评分方法，用于比较模型在某些能力上的表现，例如知识问答、数学、代码或图像理解。

【这是一个比方】 它像统一考试：同一批题有助于横向比较。

【比方的边界】 考试高分不等于实际工作全面可靠。厂商可能针对常见题训练，测试也可能与普通用户的中文、长文档和真实性需求不一致。

延迟 (latency)

准确解释： 延迟是从用户发出请求到系统开始或完成返回结果所需的时间。模型大小、网络、排队和工具调用都会影响延迟。

【这是一个比方】 它像点餐后等多久开始上菜。

【比方的边界】 快慢不只由“后厨水平”决定，也受网络、服务器负载和回答长度影响。更快不表示更准，更慢也不自动表示思考更深。

速率限制 (rate limit) 与使用额度 (quota)

准确解释：速率限制规定一段时间内最多能请求多少次或处理多少 Token；使用额度规定账号可使用的总量或资源量。

【这是一个比方】 速率限制像闸机控制每分钟进多少人，额度像一张票一共允许进几次。

【比方的边界】 不同产品按次数、Token、图片、计算时间或积分计量，不能只看“无限”两个字。所谓无限通常仍受公平使用规则限制。

模型版本 (model version)

准确解释：模型版本标识某次训练、更新或部署的模型。App 版本、模型版本、搜索版本和知识库版本是不同东西。

【这是一个比方】 App 像电视机外壳，后台模型像电视台播出的节目；外壳没换，节目仍可能已经改版。

【比方的边界】 软件系统可以在一次请求中路由多个模型，也可能使用不公开的内部版本，因此真实情况比电视比方更复杂。

开放权重（open weights）与闭源服务（proprietary service）

准确解释：开放权重通常指模型训练后的参数文件在某种许可证下可下载使用；闭源服务通常只通过 App 或 API 提供能力，不公开核心权重。开放权重不必然等于所有训练数据和代码完全开源。

【这是一个比方】 开放权重像允许把一台成品机器带回自己的厂房运行；闭源服务像只能把订单交给对方工厂加工。

【比方的边界】 拿到“机器”仍需要设备、技术和安全维护；许可证也可能限制用途。闭源服务也可能提供更好的维护和安全控制。

本册资料来源 与核验说明

核验日期：2026 年 8 月 12 日。本册介绍的是模型家族和工程方法，不给厂商做总排名。论文中的实验结果只支持论文测试过的模型、数据和任务；模型更新后，结论的强弱可能变化。

模型家族、隐私与生命周期

- NIST AI 风险管理框架：用于 AI 系统生命周期、风险、人工监督和测试验证的通用边界。
- NIST 隐私框架：支持隐私要从数据处理、治理和风险管理判断，而不能只由模型参数多少推出。

嵌入、语义检索与 RAG

- Sentence-BERT 原始论文：支持把句子映射为可用

余弦相似度比较的嵌入，
并用于语义相似检索。

- NeurIPS 2020 : RAG 原始论文：支持检索器与生成模型结合；论文使用开放域知识源，说明 RAG 并不只限于封闭的指定文件。
- PMLR : RAG 知识源投毒与检测研究：支持检索资料可能被污染、相关片段不自动等于权威事实。

微调、工具、智能体与上下文

- [LoRA 原始论文](#)：用于区分全量微调与冻结基础权重、训练新增适配参数的参数高效微调。
- [NIST 生成式 AI 风险管理框架 NIST AI 600-1](#)：用于生成式 AI 虚构、数据隐私、信息完整性和人类监督风险。

- TACL 2024 : Lost in the Middle : 在多文档问答和键值检索实验中发现，相关信息位置变化会显著影响一些长上下文模型的表现；支持“窗口放得下不等于每处都能稳健使用”。

怎样理解这些来源

“小模型” “大模型” “多模态” 和 “智能体” 没有一个能覆盖全部产品的单一尺寸线或营销名称。隐私主要取决于是否本机处理、是否上传、权限、遥测、日志、账号管理和服务政策。选择工具时，应以自己的任务、当前版本和可重复测试为准。