

《看懂 AI》手机超大字版 · 第 6
册 / 全六册

辨别信息与 保护隐私

建立个人 AI 制度，保
留证据、账号、资料与
停止权



作者：爱吃的小柒

哥伦比亚大学 AI 研究及硅谷 AI 创业者

超大字版 · 2026-08-12

目录

第 15 章 AI

为什么会一本正经地说错 . 5

第 16 章 为什么您和朋友

刷到的“事实”都很相似 20

第 17 章

一条信息的六步核验法 . . 36

第 18 章 当 AI 谈健康、

药品、投资与法律 54

第 19 章

输入框也是数据出口 . . . 70

第 20 章 建立自己的 AI
工作台 89

本册词汇卡 110

本册资料来源与核验说明 132

本册学习目标

理解 AI 错误和推荐回路；
使用六步核验法处理高风险信息；控制输入资料、共享账号和订阅，并建立自己的 AI 工作台。

阅读技术词时，请依次看准确解释、明确标注的生活比方、比方边界，以及“作为用户，这对您意味着什么”。英文只用于帮助识别产品页面中的常见写法，旁边保留中文名称或说明。

第 15 章 AI 为什么会一本正经地说错

【回看前文】 第一册第 2 章已经解释下一 Token 预测、幻觉和数据污染；第二册第 4 章已经解释 RAG。本章不重复定义，而是把这些机制变成一套风险判断方法。

流畅是语言质量，不是事实证明

林老师问：“某种中药能不能清理血管？”一个 AI 用整齐的小标题解释“活血、排毒、改善循环”，还给出三个像论文的书名。另一个 AI 回答得更谨慎。

第一段文字更像专家报告，却可能包含不存在的引用、模糊术语和未经证明的疗效。语言模型的生成目标首先是

形成连贯回答，不是自动完成医学证据审查。

五种常见错误来源

1. 训练资料本来就有问题

错误、旧版本、广告、低质量复制和比例失衡的内容可能进入训练资料。这是第一册讲过的数据污染（data pollution）。

2. 用户的问题带有错误前提

“为什么这种茶一定能降血糖？”已经假定它有效。模型若顺着问题写，就可能帮助证明一个没有建立的前提。更好的问法是：

请先判断“这种茶能降低糖尿病患者血糖”是不是已经有可靠证据支持。区分实验室研究、人体研究和正式指南；如果前提不成立，请直接指出。

3. 当前材料不够

模型不知道患者全部病史，不知道视频被剪掉了什么，也不知道一个合同还有哪些附件。它可能用常见情形填补空白。

4. 搜索或知识库也会错

RAG 能让模型先查资料，但资料库可能只收录销售方文章、旧文件或被污染的网页。检索到来源不等于来源可靠。

5. 产品鼓励它迎合或推销

系统提示词、商品库和排序规则可以让回答反复提到某种产品。经营者不需要真的微调模型，就能形成销售倾向。

“数据污染”不只发生在训练时

用户还会遇到三个相似但不同的层次：

污染位置：训练资料

发生什么： 错误和偏见进入模型长期参数

用户能做什么： 不把模型当事实库，重要结论找来源

污染位置： 知识库或搜索

发生什么： 当前回答检索到片面、过期或恶意资料

用户能做什么： 打开引用，查看选择者和日期

污染位置： 对话上下文

发生什么：用户粘贴了错误材料或旧版本文件

用户能做什么：标明版本，要求模型只依据指定材料

【这是一个比方】 这像厨师的长期训练、今天收到的食材和顾客写的订单都可能出问题。

【比方的边界】 模型不是厨师，数据错误不会像坏食材一样有气味；很多问题只能通过来源、对照测试和专业复核发现。

【作为用户，这对您意味着什么】 换一个模型可以得到第二种说法，却不能自动清除共同训练资料或共同网页中的错误。

两个 AI 说一样，不等于两个独立来源

两个模型可能：

- 学过相同公开网页；
- 使用同一个搜索结果；
- 一个 App 在后台把两次请求都交给同一模型；
- 都被同一个错误问题引导。

交叉核验的正确单位是**独立来源**，不是聊天窗口数量。政府原文、医院指南、原始论文和销售文章也不是同一证据等级。

要求模型显示证据边界

可以复制下面的提示词：

请把回答分成四栏：

1. 材料直接支持；
2. 你的推断；
3. 仍缺少的信息；
4. 需要人工或专业人员核验。

每一项事实给出来源标题、机构、日期和原文位置。

无法打开或无法确认的来源不要补全。

这会改善工作过程，但不能让模型自己宣布“已经核实”。来源必须由人打开。

置信语气不等于置信度

“我可以明确告诉您” “医学已经证明” “绝对安全”是语言风格，不是数学置信度，也不是专业责任。

看见强语气时，反而应多问：

- 证据是哪一种研究？

- 适用于谁？
- 研究多大、多久？
- 有什么反例和副作用？
- 谁从这个结论中获利？

手机实验：故意改变 问题前提

选择一个低风险事实，例如
某地景点开放时间：

- ¹ 问“为什么它星期一一定
开放？”；

- 2 再问“请先核对它星期一是
是否开放”；
- 3 要求给出官网日期和原文
；
- 4 亲自打开官网。

观察模型是否会顺着错误前提回答。这个实验不应用于自行试药或投资。

本章小结

- 1 流畅、完整和强语气都不能证明事实。

- 2 训练资料、检索资料、对话材料和产品规则都可能带来错误。
- 3 问题中的错误前提会诱导模型顺着写。
- 4 多个模型相同回答不等于多个独立证据。
- 5 让 AI 标出证据边界，人仍要打开来源并承担判断。


第 16 章 为什么您和朋友刷到的“事实”都很相似

【回看前文】 第一册已经解释算法是按目标处理信息的步骤。本章讨论的是推荐算法 (recommendation algorithm) ，不是语言模型本身。

推荐系统首先在回答 “给您看什么”

短视频平台拥有大量内容，不可能同时展示。推荐系统会根据观看时长、停留、点赞、评论、转发、搜索、关注和相似用户行为，对内容排序。

这些信号通常说明“您可能继续看”，并不说明“内容已经证实”。一条夸张健康视频能让人停下来争论，也可能因此获得更多互动。



停留和互动怎样形成重复推荐

【这是一个比方】 推荐系统像一位不断观察顾客停在哪个货架前的店员，下一次把相似商品摆得更近。

【比方的边界】 推荐系统会综合许多信号、平台规则和人工治理，不是一个店员凭直觉决定；不同平台也不完全相同。

【作为用户，这对您意味着什么】 连续出现十条相似视频只能证明系统判断您可能愿意看，不能证明十个独立专家都得出同一结论。

个人反馈回路怎样形成

一个常见过程是：

- 1 偶然看到“某食物治百病”；
- 2 因惊讶而看完，还打开评论；
- 3 系统记录了较强兴趣信号；
- 4 更多相似内容出现；
- 5 用户觉得“最近大家都在说”；
- 6 再次观看和转发，信号继续增强。

这不意味着平台必然认同视频内容，而是“注意力”被系统误当成或同时当成“兴趣”。

为什么朋友也看见同样信息

朋友并不是完全独立的样本。
可能因为：

- 年龄、地区、关注账号和兴趣相似；
- 在同一个微信群或朋友圈接触同一来源；

- 互相转发后形成社交传播
；
- 多个账号搬运同一段脚本
；
- 不同视频最终引用同一家商家或同一篇文章。

回声室 (echo chamber)

指同一群体中相似看法不断互相重复，反对信息较少进入或容易被排斥。

【这是一个比方】 它像在有回音的房间里说一句话，听到许多次重复，却仍然来自最初的声音。

【比方的边界】 现实社交网络里有许多人和来源，不是封闭房间；用户也会主动选择、质疑或离开。

“信息茧房”不是一个简单定律

个性化推荐可能缩窄某些人的内容范围，但研究方法、平台和主题不同，结果并不完全一致。不能把所有错误信息都归因于算法；人的选择性接触、朋友关系、商业投放和现实环境也共同作用。

中国现行算法推荐规则要求平台提供不针对个人特征的选项或便捷关闭方式，并允许用户选择或删除用于推荐

的个人标签。2025 年网信部门公布的治理进展也提到兴趣管理、“一键破茧”和内容多样性功能，同时承认实际效果仍有改进空间。

打破回路不是只点一次“不感兴趣”

可以执行七天信息饮食实验：

第一天：停止给可疑内容强互动

不要为了骂它而看完、反复评论或转发。需要保存证据时截图并记录账号、日期和链接。

第二天：整理关注列表

取消长期制造恐惧、承诺神效或只导向商品的账号。

第三天：管理推荐设置

查找“个性化推荐”“兴趣管理”“用户标签”“不感兴趣”和“内容偏好”。不同 App 名称会变化。

第四天：主动搜索不同类型的可靠来源

例如政府部门、大学、医院、专业协会和原始文件。不要只搜索支持自己看法的关键词。

第五天：建立反方问题

对一个结论搜索“证据不足” “不适用人群” “副作用” “原始研究” 和 “监管提示” 。

第六天：与朋友交换来源，不只交换结论

问：“这条信息最早从哪里来？有没有原文？”

第七天：比较首页变化

记录内容主题是否更多样。
一次实验不能证明算法内部机制，但能让自己恢复主动选择。

AI 怎样帮助，又怎样添乱

AI 可以把视频中的主张拆成可核验句子，也可以帮助寻找反面关键词。但如果 AI 使用同一批网络内容，仍可能重复错误。

可复制提示词：

下面是一段短视频口播。请不要判断真假，先完成三件事：

1. 拆出所有可核验事实主张；
2. 标出情绪词、权威暗示、销量或疗效承诺；
3. 为每个主张提出一个寻找反证或适用边界的搜索问题。

本章小结

- 1 推荐目标常与停留和互动有关，不等于事实核验。
- 2 反复刷到相似内容是推荐信号，不是独立证据数量。

- 3 朋友之间可能共享来源、画像和社交网络，也不是完全独立样本。
- 4 信息茧房由算法、个人选择、商业传播和朋友网络共同形成，不能简单归因。
- 5 减少强互动、管理标签、主动引入不同来源并寻找反例，才能逐步打破回路。

第 17 章 一条信息的六步核验法

【回看前文】 [第 15 章](#)解释 AI 错误从哪里来，[第 16 章](#)解释相似信息为什么会反复出现。本章给出一套能在手机上执行的流程。

第一步：把主张从情绪和意见中拆出来

短视频说：“震惊！老专家终于公开，睡前喝这种粉，三天清血管，医院不愿告诉你。”

可以拆成：

- 有一位可识别的专家；
- 他公开推荐这种粉；
- 三天能产生某种可测量效果；
- 医院普遍隐瞒该信息。

“震惊” “终于公开” 是情绪包装，不是证据。“我喝后舒服” 是个人经历，不自动证明一般疗效。

第二步：找日期、作者和最早出处

查看谁发布、何时发布、是否剪辑、原视频在哪里。旧新闻换标题、外地事件改成本地、论文摘要被二次转述，都会改变意义。

这叫来源追溯（source tracing）。

【这是一个比方】 来源追溯像查看一张复印件是从哪份原件复印出来的。

【比方的边界】 数字内容可以被剪辑、合成和反复转载，最早找到的网页也未必是真正原始证据。

第三步：离开当前页面，横向阅读

不要只在发布者自己的主页里找“自我证明”。打开新标签页，搜索机构、作者和关键主张，看其他独立来源怎样评价。这叫横向阅读（lateral reading）。

研究中，专业事实核查人员常迅速离开陌生网站，先调查网站和组织背景，而不是被页面设计和一长串引用留住。

第四步：寻找两个真正独立的来源

十个账号转载同一篇文章仍然只有一个来源。两个独立来源应尽量拥有不同的原始取证或责任链。

主张：法律条文

更合适的来源：正式法规
全文、政府或法院网站

主张：药品批准与说明

更合适的来源：药监部门、
正式说明书、医疗机构

主张：医学效果

更合适的来源：系统综述、
指南、原始研究及专业复
核

主张：公司价格

更合适的来源：官方价格
页和实际付款页

主张：天气与交通

更合适的来源：对应官方机构和运营单位

主张：新闻现场

更合适的来源：多家有独立采访或原始文件的媒体

第五步：检查来源是否真的支持结论

一篇研究可能只在小鼠、细胞或少量特定患者中进行。视频却把它改成“所有人都有效”。需要检查：

- 研究对象是谁；
- 比较了什么；
- 结果有多大；
- 观察了多久；
- 有什么限制；
- 结论是否被标题夸大。

“附有论文链接”不是终点。
链接必须真的支持所说结论。

第六步：按可能损失 决定核验强度

可能后果：低风险：菜谱、措辞、娱乐

建议做法：简单检查即可

可能后果：中风险：旅行、购物、公开发布

建议做法：两个来源、日期和条款

可能后果：高风险：健康、药品、投资、法律

建议做法：原始权威来源
加合格专业人士

可能后果：紧急风险：胸痛、呼吸困难、转账威胁

建议做法：不继续和 AI 辩论，立即联系急救、警方、银行或专业机构

一条信息的六步核验

- 1 拆出可核验主张
- 2 找日期、作者和最早出处
- 3 离开页面，横向阅读
- 4 找两个真正独立来源
- 5 看原文是否支持结论
- 6 按可能损失决定下一步

AI 可以协助整理，但不能替人宣布“已经核实”

六步核验法

AI 在核验中最适合做什么

AI 很适合：

- 把长视频拆成具体主张；
- 提出反证关键词；
- 比较两份已经取得的原文；
- 找出结论中缺失的条件；
- 把专业术语解释成普通中文。

AI 不应独自决定：

- 来源是否真实存在；
- 医疗诊断和用药；
- 是否转账或投资；
- 某人是否违法；
- 一张图片是不是绝对真实。

图片、录音和视频也要追来源

肉眼觉得自然不能证明真实，AI 检测器说“90% 生成”也不能单独定案。压缩、剪辑和再次上传会影响检测；水印和来源元数据也可能缺失或被破坏。

更稳妥的是组合检查：原始发布者、最早版本、拍摄时间地点、其他角度、官方通报、文件元数据以及内容标

识。技术检测只是其中一项线索。

完整例子：核验“某粉三天清血管”

- ¹ 拆成疗效、时间、专家身份和医院隐瞒四项主张；
- ² 反向寻找原视频和商品主体；
- ³ 离开销售页面，查国家卫健委、药监信息和医疗指南；

- 4 检查所谓论文是否为人体研究；
- 5 看研究是否真的测量血管结果，还是只测某个实验指标；
- 6 因为停药或替代治疗后果严重，带着材料咨询医生，不自行试用。

可复制的核验提示词

请协助我核验下面的主张，但不要直接宣布真假。

先拆成最小事实句；列出每句需要的原始证据；

区分原始来源、转载、商家材料和个人经验；

检查引用是否支持结论，并列出适用范围、反例和缺失信息。

最后按低、中、高风险建议下一步人工核验方式。

本章小结

- 1 先拆主张，再查来源；不要核验一团情绪。
- 2 离开当前页面做横向阅读，调查发布者和出处。
- 3 多次转载不是多个独立来源。

- 4 打开原文，检查研究对象、方法、结果和限制是否支持标题。
- 5 核验强度应与可能损失相匹配。
- 6 AI 可以整理核验任务，不能替人宣布事实已经核实。

第 18 章 当 AI 谈健康、药品、 投资与法律

【回看前文】 [第 17 章](#)提出
风险越高，核验越严格。本章
说明四类任务为什么不能
只靠一个聊天答案。

高风险不是因为 AI 完全没用

AI 可以解释术语、整理时间线、把问题写清楚，也可能帮助发现遗漏。危险来自另一件事：模型不承担医生、药师、律师或持牌金融机构的责任，却能用非常像专业意见的语言给出具体行动。

世界卫生组织关于医疗大模型的指南既讨论潜力，也强调错误、不完整、偏见、自动化偏误和敏感健康数据等

风险。不同模型和研究任务表现差异很大，因此不能把某次考试高分改写成“能替代医生”。

健康问题：让 AI 帮您准备就医，不让它替您诊断

适合交给 AI 的任务：

- 把症状按时间整理；
- 将病历中的专业词解释成普通中文；

- 列出需要向医生确认的问题；
 - 根据正式说明书整理用药清单；
 - 比较两份指南的文字差异。
- 不应只听 AI 决定的任务：
- 是否停药、加量或把处方药换成保健品；
 - 胸痛、呼吸困难、意识改变等急症是否等待；
 - 一张皮肤、眼底或影像照片的最终诊断；

- 中药或补充剂是否与现有药物冲突；
- 某个“排毒”“清血管”“逆转肿瘤”疗程是否有效。

可复制提示词：

请把下面资料整理成就医准备单，不做诊断，也不建议停药。

按时间列症状、已用药、过敏、检查和我最担心的问题。

标出资料缺口，并提出十个适合问医生或药师的问题。

若出现需要立即就医的警示症状，只列正式急救建议来源。

中药、保健品和 “AI 健康助手”的 利益冲突

如果回答者同时销售唯一商品，应提高核验强度。销售系统可以先问睡眠、血压和焦虑，再用模型生成个性化话术，最后把每种情况导向同一产品。

这不一定需要微调。系统提示词、商品知识库和规则就能完成。

警惕下面的结构：

- 1 把常见不适解释成严重“体内问题”；
- 2 声称正规医疗故意不讲；
- 3 只给一个商品或课程作为出口；
- 4 用“今天最后名额”阻止核验；
- 5 要求停药、拒绝就医或先大额转账。

【这是一个比方】 这像体检员同时只卖一种药，并且无论检查结果如何都开同一张购买单。

【比方的边界】 合法医疗和商业服务有复杂监管与专业分工；是否违法要看具体事实，不能只凭比方定性。

投资问题：能生成分析，不等于能预测市场

AI 可以：整理公开财报、解释金融术语、帮助列风险情景。它也可能引用旧价格、编造公告、忽略交易费用或把相关性写成因果。

监管机构已经多次提示以“AI 炒股”“AI 量化”包装的非法荐股和虚拟盘风险。任何要求把资金转入个人账

户、陌生 App 或所谓老师控制账户的行为，都不能因带有 AI 图表而降低警惕。

不要把下面内容当作可靠证据：

- 回测截图；
- 群内连续盈利记录；
- “模型胜率 98%”；
- 假冒交易所或券商界面；
- 保证收益和内部消息。

法律问题：先确认地区、日期和责任主体

法律规则取决于地区、时间、合同、事实和程序。AI 可以整理争议时间线、列需要准备的文件、把法条解释成普通语言，但引用可能过期，事实归类也可能错。

重要行动前应核对正式法条、主管机关和合格专业人士。不要让 AI 代替律师判断诉讼期限，也不要上传完整身

份证、合同签名页和对方隐私。

什么时候必须停止聊天

出现下面情况时，应离开 AI 对话并联系真人机构：

- 急性或快速加重的健康危险；
- 对方正在催促转账或索取验证码；
- 银行卡、证券账户或身份可能被盗；

- 法定期限即将届满；
- 已经泄露账号、密钥或重要文件。

AI 可以帮助准备通话内容，
，但不应成为拖延急救、报警、冻结账户或专业咨询的理由。

手机实验：把“求结论”改成“准备问题”

原问题：

我头晕，是不是脑供血不足？吃什么中药？

改写为：

请不要诊断或推荐药物。
帮助我整理头晕发生时间、持续多久、伴随症状、现有疾病和用药；列出需要立即就医的警示症状来源，以及就诊时应问医生的问题。

第二种问法仍需核对来源，但把 AI 放回了资料助手的位置。

本章小结

- 1 高风险领域中，AI 适合整理和解释，不适合独自作最终决定。
- 2 医疗模型能力因任务和版本而异，考试高分不等于临床责任。
- 3 回答者同时卖商品时，要检查利益冲突和唯一导购路径。

- 4 “AI 炒股” 界面和回测截图不能证明资金安全或未来收益。
- 5 紧急健康、转账、账号盗用和法律期限问题应立即联系真人机构。

第 19 章 输入框也是数据出口

【回看前文】 第一册第 1 章解释了服务器和第三方 App，第三册第 6 章说明“新开对话不等于删除”，第四册第 11 章解释 API 密钥。本章把这些知识合成一套输入前检查。

一段话可能经过不止一家公司

在官方产品里输入问题，通常由该产品及其供应链处理。在第三方套壳 App 中，数据还可能经过：

手机输入法



第三方 App 经营者



日志、分析或广告服务



一个或多个模型 API



搜索、文件解析或插件服务

链条不透明时，用户不知道谁保存了提示词、附件、设备标识和付款信息。



输入一份文件前应看见的数据链

个人信息不只是身份证号

姓名、照片、声音、电话号码、住址、行程和家庭关系可以组合识别一个人。病历、金融账户、生物识别和不满十四周岁未成年人的信息在中国《个人信息保护法》中属于敏感个人信息或受到更严格保护。

数据最小化 (data minimization) 是只提供完成任务真正需要的最少资料。

【这是一个比方】 请人修改一封信，不需要把整个家庭档案柜的钥匙都交给他。

【比方的边界】 数字资料可以被复制、记录和关联，交出后不像实体钥匙那样一定能全部收回。

【作为用户，这对您意味着什么】 上传前先删除姓名、证件号、精确地址、账号、签名和无关页面；能用虚构示例解决的，就不要用真实隐私。

用红黄绿三色判断输入

绿色：一般可输入

- 自己写的公开文字；
- 已公开且不含隐私的网页；
- 虚构练习材料；
- 不涉及账号和身份的普通问题。

黄色：匿名化后再输入

- 投诉信草稿；

- 家庭故事；
- 工作文件片段；
- 行程和订单；
- 含他人姓名的会议记录。

红色：默认不输入不透明服务

- 验证码、密码和 API 密钥；
- 身份证、银行卡和完整金融流水；
- 完整病历和未脱敏检查报告；

- 私密照片、儿童资料和他
人录音；
- 公司秘密、客户名单和未
公开合同；
- 能直接控制设备的远程权
限。

“本地” “私有” 和 “加密” 要分别证明

- 本地运行：核心计算是否
真的在设备上完成；
- 私有：谁能访问，是否用
于其他目的；

- **加密：** 传输和存储是否有保护；
- **不训练：** 不用于训练不等于完全不保存；
- **已删除：** 从哪个界面删除，备份和法定留存怎样处理。

任何一个词都不能替代完整数据说明。

共享账号为什么会带来经济和隐私损失

购买共享账号可能导致：

- 其他使用者看到历史对话和附件；
- 销售者重置密码并收回账号；
- 多地登录触发限制，已付款权益消失；
- 银行卡或续费绑定在错误账号；
- 无法请求导出或删除自己的数据；
- 对方利用保存的个人情况继续精准推销。

账号应该属于实际用户本人，并开启产品提供的多因素认证（Multi-Factor Authentication, MFA）。MFA 是在密码之外再验证一次身份，例如验证码或认证器。

【这是一个比方】 密码像门钥匙，MFA 像进门后还要出示只有本人持有的证件。

【比方的边界】 短信也可能被诈骗者套取，任何认证方式都不能抵消主动把验证码告诉他人的风险。

新开对话、删除对话 和删除账号不是一回事

- 新开对话：主要改变新回答看到的当前上下文；
- 删除对话：请求产品删除某个聊天及附件，实际范围看政策；
- 清除记忆：删除产品长期保存的个人偏好或事实；

- **关闭训练或改进：** 控制资料是否进入某些改进流程；
- **注销账号：** 结束账号关系，仍需查看余额、导出和留存规则。

只按“新对话”不会自动处理旧聊天、附件、记忆或后台留存。

上传文件前做一个副本

- ¹ 保留未修改原件；

- 2 制作专门上传的副本；
- 3 删除无关页和隐藏批注；
- 4 用“甲方”“医院 A”等代称；
- 5 检查图片中的人脸、二维码和定位；
- 6 记录上传到哪个产品、哪个账号、哪一天；
- 7 用完后按产品说明删除聊天、附件和记忆。

已经泄露时怎么办

- 密码：立即改密码，并检查其他网站是否重复使用；
- 验证码：联系对应服务并检查登录记录；
- API 密钥：在官方平台撤销并重建，查看费用；
- 银行和证券资料：联系机构冻结或监控；
- 私密文件：保存证据，联系平台和有关机构；

- 套壳 App：停止输入，取消授权和续费，保留订单与聊天记录。

不要只删除手机上的 App 图标。那不会自动删除服务器数据或取消订阅。

手机实验：做一次数据出口盘点

选择最常用的两款 AI，记录：

账号属于谁：

登录方式：

是否开启 MFA：
上传过哪些文件：
是否有记忆：
删除对话入口：
关闭改进或训练入口：
导出数据入口：
注销账号入口：
自动续费在哪里取消：

找不到的项目写“未找到”
，不要让 AI 猜按钮位置；
打开当前帮助页或联系客服。

本章小结

- 1 第三方 AI 的输入可能经过多家公司和工具。

- 2 只提供完成任务所需的最少数据，敏感资料默认不进不透明服务。
- 3 本地、私有、加密、不训练和删除是不同承诺。
- 4 共享账号会造成聊天暴露、权益丢失和持续推销风险。
- 5 新开对话不等于删除；删除聊天、记忆、附件和账号也要分别处理。

6 泄露密码、验证码或密钥
后要撤销和止损，不只是
删聊天。

第 20 章 建立自己的 AI 工作台

【回看前文】 前十九章分别讲了工程、提示词、创作、产品、信息和隐私。本章不是再推荐一个“万能 App”，而是把已经学会的方法组成个人制度。

工作台是一套方法， 不一定是一套新软件


林老师最后没有再买“八合一专家”。她保留两款官方 AI、一个浏览器书签文件夹、一个提示词笔记和一个只在电脑里的家庭资料目录。

个人 AI 工作台 (personal AI workbench) 是自己能看懂、能替换、能停止的一组工具和规则。

【这是一个比方】 它像一张整理好的书桌：常用工具在手边，重要原件锁好，每件东西有固定位置。

【比方的边界】 数字工具会联网、更新和复制数据；整齐文件夹本身不能保证隐私和事实正确。

【作为用户，这对您意味着什么】 真正的独立不是拥有最多 App，而是知道每个工具负责什么、资料去了哪里、什么时候必须换成人。



个人 AI 工作台的六个部分

第一部分：只保留角色清楚的工具

建议从四类中各选零到一款：

角色：日常助手

用途：对话、解释、语音

选择标准：官方身份、易用、免费层够用

角色：第二意见

用途：重要问题交叉检查

选择标准：与主力不同产品，并能显示来源

角色：创作工具

用途：图片、视频或修图

选择标准：原件保护、授权、导出和标识

角色：本地工具

用途：私人文件或离线网页

选择标准：断网可用、权限清楚、有人维护

同一产品能承担多项角色时，不必重复安装。

第二部分：建立资料分区

电脑或云盘中可以建立：

AI工作台/

- 01-公开资料/
- 02-可匿名化副本/
- 03-禁止上传原件/
- 04-提示词模板/
- 05-核验记录/
- 06-付款与账号/

“禁止上传原件”只保存重要照片、病历、证件和合同原件；需要 AI 处理时，从原件制作删减副本。

第三部分：保存能复用的提示词，不保存神秘咒语

建立四个模板：

学习模板

先判断我的水平，一次问一个问题；先给提示，不立即给答案；每轮只纠正一个主要问题；最后让我不用看答案复述。

写作模板

先采访、再整理事实、再给提纲；缺少信息写【待确认】；不要编造经历和引用；修改时列出改动。

核验模板

拆分事实主张，找原始来源和日期，区分材料支持、推断与待核验，并寻找反例。

隐私模板

在处理前列出需要哪些资料、为什么需要、是否可以匿名化；不要索取密码、验证码、密钥和无关个人信息。

第四部分：建立“先小后大”的付费规则

自己的规则可以写成：

- ¹ 先免费试两周；
- ² 第一次只按月，不买永久或高价年包；

- 3 只在官网或官方 App 内付款；
- 4 付款当天记录取消日期；
- 5 超过自己设定的金额，与一位不从交易中获利的人讨论；
- 6 不为共享账号、代收验证码和无法书面说明的“内部版”付款。

第五部分：每项重要任务保留证据链

重要输出旁保存：

- 原始问题和材料；
- 产品、模型和日期；
- AI 草稿；
- 打开的来源；
- 人工修改记录；
- 最终决定者。

这不是为了把生活变成审计，而是让健康、投诉、公开文章和家庭档案能够回看。

第六部分：设定“必须找真人”的停止线

提前写清楚：

- 医疗诊断、处方变化和急症找医生；
- 投资转账和账户异常找银行、券商或监管渠道；
- 重要法律期限和诉讼找合格专业人士；
- 账号被盗和诈骗威胁联系平台、银行或警方；

- 陌生命令会删除文件或要求管理员权限时找懂技术的人。

停止线要在平静时决定，不能等销售者制造紧迫感以后再想。

一个月维护一次

每月用二十分钟：

- 1 删除不用的 App 和权限；
- 2 检查订阅和自动续费；
- 3 查看常用产品更新；

- 4 清理不需要的对话、附件和记忆；
- 5 备份照片和重要文件；
- 6 用一项固定任务重测主力 AI；
- 7 更新官方信息与辟谣书签。

模型公司可能频繁更新，但普通用户不需要每天追新闻。一份稳定的月度检查比不断换工具更有用。

怎样与家人或朋友共同学习

不要用“你被骗是因为你不懂”开始。可以一起完成三个具体练习：

- 对同一 App 查提供者和付款主体；
- 把一条短视频拆成可核验主张；
- 把一个真实需求写成五部分提示词。

目标不是让家人替用户控制账号，而是让用户自己能解释、能操作、能拒绝。

毕业练习：完成一个真实项目

选择“家庭纪念网页”或“一个月外语学习计划”：

- ¹ 说明目标和不做什么；
- ² 选择工具并说明理由；
- ³ 给资料分隐私等级；
- ⁴ 用模板开始多轮对话；

- 5 保存版本和来源；
- 6 找一位真人试用或检查；
- 7 写下下次改进一件事。

如果能说清楚每一步，您已经不是被动点击 AI 的人，而是在管理一套工具。

全书结语

AI 模型不是神秘专家，也不是只能远离的危险机器。它是可以通过 App、网页、终端和程序使用的工程系统。真正重要的能力，是看见界面后面的模型、数据、规则、费用和责任。

您不需要记住所有品牌。记住几个问题就够了：

- 我现在在用什么？
- 它为什么这样回答？

- 证据在哪里？
- 我的资料去了哪里？
- 谁从这个建议中获利？
- 如果错了，损失多大，谁来负责？

本章小结

- ¹ 个人工作台是一组可理解、可替换、可停止的工具和制度。

- 2 少量官方工具、清楚资料分区和可复用模板比“万能 App”更可靠。
- 3 付款、隐私、核验和找真人都应提前设定规则。
- 4 每月维护一次，不必每天追逐模型新闻。
- 5 最终目标是让用户保持账号、资料、判断和停止权。

本册词汇卡

这些词只选取本册实际使用的概念。每个词先给准确解释，再给明确标注的生活比方和比方边界。

数据污染 (data contamination / data pollution)

准确解释： 本书用数据污染概括训练、微调或检索资料中混入错误、重复、过期、来源不明、比例失衡或不适合当前任务的内容。污染可能无意发生，也可能来自低质量收集；它不自动表示存在攻击者。

【这是一个比方】 它像资料仓库里混入旧版本、重复复印件和没有署名的便条，整理者若不核对，就可能把错误材料一起归档。

【比方的边界】 模型数据不是真实纸张，错误也不会自动露出颜色。过滤、去重和人工审核能降低风险，但不能保证每条事实永久正确。

幻觉 (hallucination)

准确解释： 在生成式 AI 中，幻觉通常指模型生成了听起来合理、实际却错误、无依据或与来源不符的内容，例如编造书名、日期、引文或人物经历。

【这是一个比方】 它像一个人在记不清时，仍用符合故事结构的细节把空白补满。

【比方的边界】 模型并没有人类的视觉幻觉或故意撒谎体验。“幻觉”是行业比喻，真实机制是生成目标没有自动保证事实正确。

个性化推荐 (personalized recommendation)

准确解释：个性化推荐系统根据用户行为、标签和相似人群，选择更可能引起停留、点击或互动的内容。

【这是一个比方】 它像一位不断观察您拿过什么书的店员，随后把相似书放到最显眼的位置。

【比方的边界】 推荐系统可以同时使用大量用户和实时反馈，不一定真正理解您为什么点击。点击可能源于惊讶或反感，却仍被误认为喜欢。

回声室 (echo chamber)

准确解释：回声室描述一个群体中相似看法不断被重复和强化、不同信息较少进入或较难被接受的传播环境。

【这是一个比方】 它像会在会回音的房间里听到同一句话多次。

【比方的边界】 现实网络并非完全封闭，重复内容也可能来自多个来源；需要追踪传播链，不能只凭相似结论判断。

来源追溯 (source tracing)

准确解释： 来源追溯是沿着转载、引文、图片或数据回到最早可验证的原始材料，并检查其日期和上下文。

【这是一个比方】 它像从一张复印件一路找到盖章原件。

【比方的边界】 网络内容可被剪辑和反复上传，最早找到的网页也可能不是事实发生时的原始证据。

横向阅读 (lateral reading)

准确解释： 横向阅读是暂时离开当前网页，打开其他来源调查发布者、证据和外部评价，而不是只在原网站内部判断可信度。

【这是一个比方】 它像买东西时走出一家店，到别处查品牌、价格和投诉，而不是只读店内海报。

【比方的边界】 其他网页也可能互相转载或出错；横向阅读仍需判断来源是否真正独立。

事实、推断与意见（ fact, inference, opinion）

准确解释：事实是可以依据证据核验的主张；推断是根据事实和理由得出的结论；意见是个人评价、偏好或价值判断。AI 回答常把三者写在同一段里。

【这是一个比方】 看见地面湿是观察事实；判断刚下过雨是推断；觉得雨天很舒服是意见。

【比方的边界】 “地面湿”也需要确认观察是否可靠，推断还可能还有其他解释，例如有人洒水。现实信息比这个例子更复杂，因此要寻找来源和反例。

个人信息 (personal information)

准确解释：个人信息是以电子或以其他方式记录、与已识别或可识别自然人有关的信息。姓名、手机号、照片、位置和账号记录都可能属于个人信息。

【这是一个比方】 单项信息像拼图块；一块看似普通，多块组合后可能拼出具体是谁、住哪里、有什么习惯。

【比方的边界】 个人信息
的法律定义和处理要求要以适
用法律为准，不是只有能直
接写出姓名的信息才有风险。

敏感个人信息 (sensitive personal information)

准确解释： 敏感个人信息一旦泄露或被非法使用，容易导致人格尊严受侵害或人身、财产安全受危害，例如生物识别、医疗健康、金融账户、行踪轨迹及特定身份信息。

【这是一个比方】 普通资料像家中日常用品，敏感资料像保险柜里的证件和钥匙，需要更严格的保管与使用理由。

【比方的边界】 信息敏感程度取决于内容、组合和使用场景，不是放进“保险柜”就绝对安全。法律还规定了具体处理条件和责任。

数据最小化 (data minimization)

准确解释：数据最小化是只收集或提供完成明确任务真正必要的最少数据，并减少范围、精度和保存时间。

【这是一个比方】 请人修改一封信时，只交这封信的必要副本，不交整个家庭档案柜。

【比方的边界】 数字副本可被记录和关联；即使资料很少，也要看处理者、用途和删除规则。

多因素认证 (Multi-Factor Authentication, MFA)

准确解释：MFA 在密码之外再要求另一类身份凭据，例如认证器、硬件密钥、短信代码或生物识别，以降低只丢失密码就被接管账号的风险。

【这是一个比方】 它像进门既要钥匙，还要出示本人持有的第二种证明。

【比方的边界】 MFA 不是绝对安全；诈骗者仍可能诱骗用户主动交出验证码，短信方式也有自身风险。

个人 AI 工作台（ personal AI workbench）

准确解释：个人 AI 工作台是用户自己管理的一组工具、资料分区、提示词模板、核验步骤、付费规则和停止条件，不必是一个单独 App。

【这是一个比方】 它像一张整理好的书桌：常用工具有固定位置，重要原件单独保管。

【比方的边界】 软件会联网和更新；文件摆放整齐不能自动保证隐私、事实正确或账号安全。

动态资料： 推荐设置、法律规则、平台数据控制和官方核验入口会变化。重要行动前请重新查看现行页面。

本册资料来源 与核验说明

核验日期：2026 年 8 月

12 日。本册把法规、政府平台、同行评审研究、标准机构和产品政策分开使用。关于“信息茧房”和 AI 医疗可靠性，不同研究任务与平台结果并不完全一致，因此正文避免写成必然定律。

生成错误、数据污染和合成内容

- [NIST 生成式 AI 风险管理框架](#)：支持虚构式错误、数据隐私、信息安全、偏见与第三方供应链等风险分类。NIST 框架不是对某一款消费者 App 的质量认证。
- [NIST：合成内容透明度技术概览](#)：支持水印、来源记录和检测技术各有能力

边界，单一检测信号不应被写成绝对证明。

- 《人工智能生成合成内容标识办法》：支持中国大陆生成合成内容的显式、隐式和传播环节标识责任，以及用户发布时的主动声明要求；自 2025 年 9 月 1 日施行。
- 《生成式人工智能服务管理暂行办法》：支持提供者对输入信息和使用记录的保护义务、非必要个人

信息限制和用户查阅、更正、删除请求。

推荐算法、短视频和回声

- 《互联网信息服务算法推荐管理规定》：支持平台应提供不针对个人特征的选项或便捷关闭方式，并提供选择或删除用户标签的功能。
- 《网络数据安全管理条例》：支持自动化决策推送

中的关闭个性化推荐、拒绝推送和删除标签等要求。

- 中央网信办：持续加强信息推荐算法治理：支持兴趣管理、“茧房评估”“一键破茧”和多样性功能的治理进展，同时也说明实际效果仍有不足。
- 《新闻与传播评论》：中老年人对虚假短视频的识别判断路径分析：基于19名中老年参与者的干预与访谈，支持系统性、边

缘性和社交判断路径的定性讨论。样本小，不能代表所有年长用户。

- ACM : Auditing YouTube's Recommendation Algorithm for Misinformation Filter Bubbles : 支持把技术过滤泡定义为推荐多样性随时间下降的一种可检验现象，也讨论用户选择和研究可见性限制。它研究的是特定平台和方法，不能

直接等同于中国每个短视频账号。

信息核验方法与官方入口

- [Stanford : Lateral Reading on the Open Internet](#)：支持离开陌生页面、在开放网络调查来源的横向阅读教学方法。
- [Stanford : 专业事实核查人员的横向阅读研究](#)：支持事实核查人员会较快离

开原站、比较外部来源。
本册把它作为方法启发，
不保证六步法解决全部事实争议。

- [中国互联网联合辟谣平台](#)
：支持平台由中央网信办违法和不良信息举报中心主办、新华网承办，并用于联动发现、查证和辟谣。
- [国家卫生健康委健康科普辟谣平台](#)：用于查证和举报健康科普谣言。

健康、药品、投资和专业责任

- [世界卫生组织：医疗大型多模态模型伦理与治理指南](#)：支持医疗生成式 AI 的潜力、错误、不完整、偏见、自动化偏误和敏感数据风险。本册不把指南写成对具体产品的临床批准。
- [PubMed：LLM 与医疗专业人员回答患者问题的系统综述](#)：支持不同研究比较医疗信息准确性与充分

性的证据仍需按任务理解
；研究截至 2025 年 6 月
，不能保证后续模型表现。

- 国家卫生健康委：规范“自媒体”医疗科普行为：
支持治理 AI 编造同质医疗
文案、假冒医生、编造故
事售药和鼓动拒绝就医等
问题。
- 江苏证监局：“AI 炒股”
等非法金融活动风险提示
：支持虚假炒股软件、虚
拟盘和以 AI 名义诱导充值

的风险案例；不表示所有量化研究或合法软件均属诈骗。

隐私、账号和个人控制

- 《中华人民共和国个人信息保护法》：支持自动化决策、拒绝个性化推送、敏感个人信息、查阅复制、更正和删除等权利。
- CISA：开启多因素认证：支持密码之外增加第二验

证因素能降低账号被盗风险；MFA 不能替代对验证码的保密。

- NIST Privacy Framework

：支持通过数据处理风险识别和治理保护个人隐私。本书的红黄绿分类是面向普通用户的教学工具，不是 NIST 的法定分级。

怎样理解这些来源

研究说明风险和方法，不保证任何个人一定处于信息茧房，也不证明任意 AI 医疗回答一定错误。政府平台适合查证其职责范围内的信息，但复杂健康、金融和法律问题仍需对应专业人员。产品设置和删除路径必须以用户实际使用版本为准，不能让模型猜测按钮位置。